# 第八章　统计量和抽样分布

前面七章我们讨论了概率论的基本内容.从本章起,将讲述统计的基本知识以及初步应用.着眼点在于让读者懂得一点统计知识,熟悉统计语言和具有统计思想,掌握几种主要的统计方法,以便能够理解和掌握现代社会所提供的统计信息的特性.

概率论是统计学的数学基础,统计学从某种角度上也可看成概率论的重要应用,然而统计学作为一门独立的学科有它自身的特点和规律,特别是统计学有着广泛的应用领域.本章将首先陈述统计学的基本概念以及统计方法的特点.

统计量是统计推断的重要工具,在往后展开的种种统计方法中将扮演主要角色.因此本章要介绍的另一内容是:统计量的概念、性质以及常用统计量的分布.

## 第一节　统计与统计学

### 一、统计的研究对象

先看两个例子.

**例 1**　某厂生产大批某种型号的元件,从某天生产的元件中随机抽取若干个进行寿命试验,检验该厂生产的元件是否合格.

**例 2**　在美国总统选举年,从所有合法选民中随机抽出一部分进行民意测验,评估两党候选人获胜的机会.

这两个例子有以下几个共同特点:首先都涉及经济、社会现象,在例 1 中是某天生产的大批元件寿命,在例 2 是美国在该选举年的所有合法选民意向;其二,它们都有相应的数量特征,称之为统计指标,它可以是数,也可以是向量,或者是定性指标的量化,如例 2 中选举意向是个定性指标,但是可以将其量化为:选共和党的标记为 1,选民主党的标记为 -1,弃权的标记为 0.类似的例子在实际生活中是普遍存在的,统计的研究对象是大量社会经济和自然现象的一定总体的数量特征及数量关系.

首先,构成统计研究对象的必须是“大量的”现象,因为少量的现象一是无规律可循,二是在有些情况下一目了然,无需使用统计手段进行研究分析;其次,统计研究的不是现象本身,而是现象所表征的数量特征或统计指标,这就区别了统计与其他

的行为科学;再次,数量特征或统计指标都有客观性,例如前例中的元件寿命、选举意向都有确定的实际内涵,这就使得统计与纯粹数学相区别,统计指标有定量、定性之分,如例 1 是定量指标,例 2 是定性指标,定性指标一般都可采用适当的方式加以量化.

同其他学科相比,如物理、化学、社会学、经济学等,它们都有已经定义的很好的某种现象作为研究对象,统计学没有属于自己的基于试验或观察的经验研究对象,而是研究普遍存在于其他学科领域的数量特征和数量关系.由于统计研究对象的以上特征,所以统计的应用范围涵盖了涉及社会、经济、自然科学的几乎所有领域.

## 二、总体和样本

在统计中,总体和样本是经常要用到的两个基本概念.

直观来说,总体就是统计问题所要研究的对象全体,其中每个对象称为个体,如上节例 1,总体是该厂某天生产的全部元件,其中每一元件就是个体;在例 2 中,总体就是该选举年全体合法选民,每个选民即个体.

然而统计的研究对象并非是现象所涉及的人和物本身,而是现象的数量特征或统计指标,因此可以直接定义总体就是研究对象的统计指标,个体就是统计指标的特定观察,如例 1 的总体就是某天生产的元件寿命,例 2 的总体是选民的选举意向(已定量化).由于统计问题涉及的是大量现象的观察,因此某个个体的出现或者说某个指标值的出现是随机的,于是更为合理的是将表征现象的统计指标看成随机变量(或随机向量).它们遵从一定分布,而分布类型则是由研究对象本身所界定的.如此一来可以给出如下的定义:统计总体是服从一定分布的统计指标,通常以大写英文字母 $X,Y$ 等记之,每个个体对应着统计指标的一个特定观测值.依照这一定义,总体是由分布所界定的,服从同一分布类型的两个研究对象可以看成来自同一总体,例如,有两个不同厂家,一个生产电视机某种元件,另一个生产电脑的某种元件,今分别考察元件寿命,如它们的寿命都服从指数分布(当然其平均寿命是不同的,因此有不同的分布参数),则可以认为它们是来自同一统计总体,总体的这一定义给理论处理带来极大的方便,尤其是便于应用概率论作为理论分析的工具.

称总体中按一定规则抽出的一部分个体为样品,样品的统计指标称为样本.

所谓"一定的规则",是指保证总体中每一个个体有同等的机会被抽到的规则.在总体中抽取样本的过程称为抽样,抽取规则称为抽样方案,样本所包含的个体个数称为样本容量.

对于给定的抽样方案,作为将要被抽到的那些个体的指标,样本是一组随机变量(或随机向量),通常用大写字母,例如 $X_1,\cdots,X_n$ 记之,其中 $n$ 为样本的大小,称为样本容量.其随机性表现在:总体中究竟哪几个个体被抽到是随机的,一旦给定的抽样方案实施后,样本就是一组数据,通常用小写的英文字母如 $x_1,x_2,\cdots,x_n$ 记之,也称之为样本值,事实上,样本值 $x_1,x_2,\cdots,x_n$ 就是样本 $X_1,X_2,\cdots,X_n$ 的一组特定的观测值.有时,也称单个观测 $X_i$ $(1\leqslant i\leqslant n)$ 为样本,或称之为第 $i$ 个样本.

**例 3**(抽样检查) 设有批量为 $N$ 的产品,其中次品数为 $N\theta,\theta$ 未知,$0<\theta<1$.今分别

按有放回和无放回两种方法从中随机抽取 $n$ $(n\leqslant N)$ 件.定义

$$X_i=\begin{cases}1, & \text{第 } i \text{ 次抽得次品},\\ 0, & \text{第 } i \text{ 次抽得正品}\end{cases}\quad (i=1,2,\cdots,n),$$

则 $X_1,X_2,\cdots,X_n$ 即是样本.且在有放回时,$X_1,X_2,\cdots,X_n$ 是独立同分布的,其公共分布是参数为 $\theta$ 的 0-1 分布;在无放回时,$X_1,X_2,\cdots,X_n$ 有相同分布但不独立.事实上可以分别给出在这两种不同抽样方式下的样本的联合分布:

(i) 有放回抽样

$$P(X_1=x_1,X_2=x_2,\cdots,X_n=x_n)=\theta^{\sum\limits_{i=1}^{n}x_i}(1-\theta)^{n-\sum\limits_{i=1}^{n}x_i}\quad (x_i=0\text{ 或 }1,i=1,\cdots,n).$$

(ii) 无放回抽样

$$P(X_1=x_1,X_2=x_2,\cdots,X_n=x_n)=\frac{C_{N\theta}^{t}C_{N(1-\theta)}^{nt}}{C_N^n}\quad \left(t=\sum_{i=1}^{n}x_i,x_i=0\text{ 或 }1,i=1,2,\cdots,n\right).$$

由此可见,即使对同一总体,因不同的抽样方式,样本的分布可以不同(但对无限总体来说,不同的抽样方式对样本分布没有影响).

常称样本的联合分布为统计模型.必须指出的是,统计模型与概率模型是不同的,统计模型中总会有未知的成分,如上例中 $\theta$ 是未知参数,概率模型则不然.

依照抽样规则的要求,一般来说,每个样本 $X_i$ 都是与总体同分布的,这就保证了样本的代表性.如还要求各个样本 $X_1,X_2,\cdots,X_n$ 是相互独立的,则称之为简单随机样本.因此,简单随机样本就是独立同分布样本.这种样本既有代表性又有独立性,便于理论分析,是使用最为广泛的一种样本.本书所涉及的样本除另有说明外,都假定是简单随机样本,简称为样本.

## 三、什么是统计学

先看一个使用统计方法处理实际问题的例子.

**例 4** 某社区计划建一所养老院,服务对象为满足一定条件的 65 岁以上的老人.在预算和规划时,需要知道一个关键参数,即当地居民的预期寿命.

为解决这个问题,第一步是收集与预期寿命有关的数据,例如该地区近十年 65 岁以上的老人死亡资料.表 8.1 是根据随机抽取的 1 000 个死亡记录整理出来的一张频数分布表.

**表 8.1 死亡年龄频数分布表**

| 死亡年龄组 | (65.5,70.5] | (70.5,75.5] | (75.5,80.5] | (80.5,85.5] | (85.5,90.5] |
|---|---|---|---|---|---|
| 组中值 | 68 | 73 | 78 | 83 | 88 |
| 组频数 | 89 | 251 | 358 | 266 | 36 |

以上最后一列已将死亡年龄≥90 的个体包括在内.以上步骤通常称为数据的收集和整理,文献上也称为描述性统计.

然后基于以上数据作出预期寿命(记为 $\mu$)估计.后文将会看到,$\mu$ 的一个常用估计

即为样本平均数.基于表 8.1,可算出 $\mu$ 的估计为 $\hat{\mu}=77.545$.于是我们可以得出结论:基于我们的数据,预期寿命的估计为 77 岁到 78 岁之间.但这样的结论不能令人信服,因为另一个人可以寻找另外一组 1 000 个死亡数据,得到的 $\mu$ 的估计低于 77,或者高于 78.又如何解释上述结果呢?作为一个完整的统计分析,应该包含得出结果(此处是 $\mu$ 的估计)的精度与可靠度,往后我们还要就这个问题做深入的讨论.

通常称这部分工作为统计数据分析或统计推断.例 4 所描述的使用统计方法解决实际问题的过程,具有普遍性.从中可以知道统计学的主要内容.概括地说,统计学就是使用有效方法收集数据、分析数据,并基于数据做出结论的一门方法论科学.它的主要内容包括抽样调查、试验设计、点估计、区间估计和假设检验等.

## 四、统计方法的特点

从什么是统计学的讨论可以看出:统计数据既是统计研究的出发点,又是统计方法加以实施的载体,而且也是推断结论的唯一实证依据.因此可以说,"一切由数据说话"是统计方法的第一个、也是最重要的特点.这一特点决定了统计方法完全不涉及问题的专业内涵,因而是一件完全"中性"的、任何人都可使用的工具.

统计方法的第二个特点是:统计分析的结果常常会出错,而且这种错并非是由方法的误用所引起的.然而与此同时,分析结论也会告诉你出错的机会不会超过一个较小的界限.一个典型的例子是每天的天气预报,当它报告一个结果:明天是晴或是雨的同时,也告诉你明天晴的概率是多少.天气预报虽然可能会出错,但谁又会怀疑天气预报的科学性和重要性呢?

统计方法的第三个特点是:统计方法研究和揭示现象之间在数量表现层面上的相关关系,但不肯定因果关系(也许,实验型数据的统计分析会有例外,因为有可能通过实验严格控制其他因素).下面是一个例子:"吸烟有害健康"的观点,现在看起来已得到社会的认同,这里有统计分析所起的作用.然而,吸烟与患肺癌之间是否有因果关系,仍然是一个引起争议的问题.1957 年,《不列颠医学杂志》上有一项统计分析报告,指出吸烟与患肺癌有很强的相关关系.这引起人们的极大关注.然而经过四五十年的努力,仍然没有确定证据表明吸烟与患肺癌有因果关系.引发肺癌的因素是十分复杂的,吸烟与患肺癌有很强的相关关系,即是说数据显示吸烟的人群中患肺癌的比率比较高,但不能由此肯定它们之间有因果关系.

统计方法的第四个特点是:使用归纳推理.所谓归纳推理就是选取适合观测结果的假设,由特殊推向一般的推理.统计数据是作为总体的一部分的样本观测值.在选定的一组假设或设定的模型下,基于数据要推断整个总体的情况,因此统计推理是归纳推理.与此相区别的数学的推理是演绎推理.演绎推理和归纳推理是两种截然不同的推理.例如对同一假设下的同一数学问题,不论任何人,由演绎推理只能得出同一个结果;但统计问题则不然,在同一个统计模型的假设下,对同一统计问题不同的人使用归纳推理可以得到不同的结果.其原因是一个统计推断结果既同采用什么样本有关,也同采取什么样的统计方法有关.如果两个人分别采用不同的样本,或者虽然使用同一组样本但使用不同的统计方法,得到的推断结果当然可以不一样.

## 五、统计思想

当代公认的统计大师 C.R.Rao 在他的专著 *Statistics and Truth* 中，从哲学角度阐述统计的思想和特征，其中有这样的一段话："19 世纪以来统计学面临种种问题，要回答这种类型的问题的主要障碍，是随机性——缺乏原因与结果之间的一一对应关系.基于随机性的基础，人们如何行动呢？这是个长时间困扰人类的问题，直到本世纪初，我们才学会了掌握随机性，发展成能做出聪明决策的科学——统计学."Rao 的这段论述表明，统计学的发展历史是同对随机性的把握相伴的，通过对看起来是随机的现象进行统计分析，推动人们将随机性归纳于可能的规律性中，这是统计思想的重要体现.概率的统计定义，概率的频率解释以及统计结果的解释和评估都是这种思想的重要表现.

统计思想另一重要表现则是对差异的把握，即从差异中发现趋势.由于随机性，同一对象不同时间的观测以及不同的对象对同一指标的观测总是有差异的.如果观测到的差异超出一定的界限，以至不能由数据本身的随机性加以解释，此时变化趋势就发生了.下面是这种表现的例子.

**例 5** 为检验一枚硬币是否均匀，独立投掷 100 次，记录正面出现的次数（记为 $X$），如假设"硬币是均匀的"（记此假设为 $H_0$）成立，则正面出现的期望频数为 50，现在考察试验结果与期望值的差异 $X-50$.

今有试验结果：正面恰好出现 61 次，则得到一个 $61-50=11$ 的差异值，这是一个不小的差异.然而基于这样大的差异能否认为：$H_0$ 不再成立，硬币偏向正面呢？注意到当 $H_0$ 事实上成立时，由于随机性的作用，也会偶尔出现差异大于 0（或是差异小于 0）的结果.因此一个可行途径是确定一个阈值，使得当"差异大于该值"这一事件发生时，不能用随机性来解释.此时拒绝 $H_0$ 是合理的，从而认定变化趋势已发生，即硬币不是均匀的.我们将在后文讨论假设检验时再回到这一问题.

## 习题 8.1

1. 某购物网站要了解消费者的购物偏好特征，于是进行了随机调查，请问该项研究的总体是什么？个体是什么？样本是什么？

2. 某高校想了解大一学生入学时的数学水平，特从新生中随机抽取 500 名进行测试.请问该项调查的总体和样本分别是什么？

3. 某品牌的咖啡饮品声称不含糖类成分，研究人员对其进行调查，从不同批次生产的饮品中随机抽取了 20 瓶进行检测，请问该项检测的总体和样本分别是什么？

4. 设 $(X_1,X_2,\cdots,X_6)$ 是取自总体 $X$ 的一个简单随机样本，在下列三种情况下，分别写出样本 $(X_1,X_2,\cdots,X_6)$ 的联合分布律或联合密度函数.

（1）总体 $X\sim P(\lambda)$；

（2）总体 $X\sim R(0,\theta)$；

（3）总体 $X$ 的密度函数为 $f(x)=\dfrac{\lambda}{2}e^{-\lambda|x|}$，$-\infty<x<+\infty$.

## 第二节　统　计　量

### 一、统计量的定义

一般来说，原始统计数据，经过初步整理后可以大致知道其分布，但这对于将要进行的统计推断是不够的.我们先看一例：以下是某厂生产的机器零件的质量（单位：kg）

215，227，216，192，207，207，214，218，205，200，

187，185，202，218，195，215，206，202，208，210，

经过初步整理后可以画出质量分布的直方图（如图 8.1 所示）.但对于具体一个统计问题来说，还需要从中提炼出少数几个指标，以概括这批数据所提供的与问题有关的信息.例如要回答：这批零件的平均质量是多少？各个零件相对于平均质量的差异有多大？这就需要基于这批数据，概括出一两个指标.统计中称这些指标为概括统计量，或统计量.

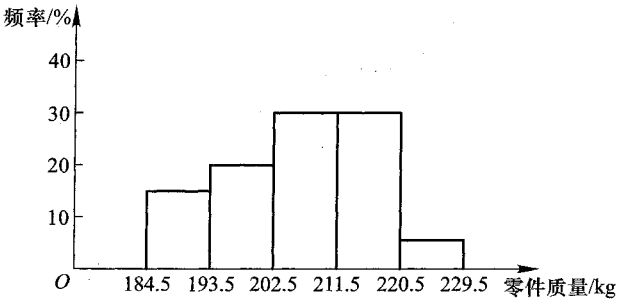



图 8.1　20 件机器零件质量频率直方图

在这个例子中，我们可以用算术平均 $\bar{x}=206.45$ kg 作为该组数据的中心位置的概括统计量，而用样本标准差 $s=10.91$ kg 作为这批数据差异或分散程度的概括统计量（其计算公式将在下面给出）.这两个指标提炼了 20 个数据所提供的上述两个问题的信息，显然要比 20 个原始数据更易于把握.下面给出统计量的定义：

称完全由样本确定的量（可以是向量）为统计量，或从数学观点来看，统计量是样本的函数（可以是向量值）.

以上定义中，“完全”这一词很重要，即它不应该同未知的总体分布有关，例如它不应含有总体分布中的未知参数，一旦有了样本数据就可以得出它的值.一般如用 $X_1$，$X_2$，$\cdots$，$X_n$ 表示容量为 $n$ 的样本，则可用 $T=T(X_1,X_2,\cdots,X_n)$ 表示一个统计量，$T$ 可取向量值，而函数 $T(X_1,X_2,\cdots,X_n)$ 应该不含任意未知参数.

由样本的性质可知：统计量是随机变量（或随机向量），作为数据加工的结果，统计量是确定的数或向量，有时也称后者为统计量观测值或统计量值.通常用 $t=T(x_1,x_2,\cdots,x_n)$ 表示当 $X_1=x_1,X_2=x_2,\cdots,X_n=x_n$ 时统计量 $T$ 的值.

典型例题
精讲视频

常用统计量
及其性质

## 二、常用统计量

常用统计量分两类：一是描述数据分布的中心位置，二是描述数据分布的分散程度.这两类统计量提供了总体分布的相应信息.

设有数据 $X_1, X_2, \cdots, X_n$，定义样本均值为

$$\bar{X}=\frac{1}{n}\sum_{i=1}^{n} X_i, \tag{1}$$

样本方差为 $S^2$，其中

$$S=\sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2}, \tag{2}$$

称 $S$ 为样本标准差.样本均值可用以描述数据的中心位置，而样本方差和样本标准差则用以刻画数据的分散程度，$S$ 越大，分散度越高.不难推出下面的简算公式：

$$S=\sqrt{\frac{1}{n-1}\sum_{i=1}^{n}X_i^2-\bar{X}^2}, \tag{3}$$

此式提供一个计算格式：为计算根号里面的量，只需计算两个算术平均，一是数据平方的算术平均，二是数据本身的算术平均.

样本均值计算简单，且历史上使用较早，但作为数据中心位置的指标还是有其缺陷的.例如对于居民年收入数据，当使用年人均收入作为贫富指标，就有可能掩盖贫富的差异，因为少数人的大量财富有可能大大提高一个地区的人均收入.对于这一类社会经济数据，通常使用样本中位数来描述数据的中心位置.

样本中位数的直观意义是：若将数据从小到大排列，中位数就是居于中间位置的数值.设 $x_{(1)}\leqslant x_{(2)}\leqslant\cdots\leqslant x_{(n)}$ 是数据 $x_1, x_2, \cdots, x_n$ 由小到大的重排，则样本中位数可如下计算：

$$med=\begin{cases} x_{\left(\frac{n+1}{2}\right)}, & \text{当 } n \text{ 为奇数,} \\ \dfrac{1}{2}\left[x_{\left(\frac{n}{2}\right)}+x_{\left(\frac{n}{2}+1\right)}\right], & \text{当 } n \text{ 为偶数.} \end{cases} \tag{4}$$

对于本节例子中的数据 $n=20$，$x_{(10)}=x_{(11)}=207$，故样本中位数 $med=207$.此例样本均值与样本中位数相当接近.

当数据的直方图显示对称性时，有

样本均值＝样本中位数.

如用中位数作为数据中心位置的指标时，一般可用极差或四分位间距反映数据的分散度.极差 $R=x_{(n)}-x_{(1)}$ $\left(x_{(1)}=\min\limits_{1\leqslant i\leqslant n}x_i, x_{(n)}=\max\limits_{1\leqslant i\leqslant n}x_i\right)$，其直观意义很明显，$R$ 即数据的振幅，振幅越大说明数据越分散.四分位间距 $H=Q_U-Q_L$，此处，$Q_L<Q_U$，分别使 $Q_L$ 的左、右的数据比及 $Q_U$ 的右、左的数据比为1∶3，也称 $Q_U, Q_L$ 为数据的上、下四分位数.

$Q_L, Q_U$ 可如下计算：

$$Q_L=\begin{cases} x_{([0.25n]+1)}, & \text{当 } 0.25n \text{ 不是整数时,} \\ \dfrac{1}{2}\left(x_{(0.25n)}+x_{(0.25n+1)}\right), & \text{当 } 0.25n \text{ 是整数时,} \end{cases}$$

其中 $[0.25n]$ 表示 $0.25n$ 取其整数部分.类似地，

$$Q_U=\begin{cases} x_{([0.75n]+1)}, & \text{当 } 0.75n \text{ 不是整数时,} \\ \dfrac{1}{2}(x_{(0.75n)}+x_{(0.75n+1)}), & \text{当 } 0.75n \text{ 是整数时.} \end{cases}$$

依定义 $H$ 正是区间$(Q_L,Q_U)$的长度,而区间$(Q_L,Q_U)$正好含有 50%的数据,因此 $H$ 是相对于中位数的数据分散度的一个确当指标.此外,若数据低于$Q_L-1.5H$ 或高于$Q_U+1.5H$,则该数据可以认为是异常值.

对于成对数据$(x_i,y_i)$,$i=1,2,\cdots,n$,固然可以对$\{x_i\}$及$\{y_i\}$分别使用上述统计量来刻画数据 $x_i$ 及数据 $y_i$ 各自的统计特征,但无法描述 $x$ 与 $y$ 之间的关联程度.

在统计中常常关心两个变量 $x$ 与 $y$ 之间有无线性关系,及线性相关的程度有多大,尽管线性关系从数学上说十分粗糙,但对一些实际问题却作用很大.一个描述成对数据线性相关程度的统计量是样本相关系数:

$$r_{xy}=\frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i-\bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i-\bar{y})^2}}, \tag{5}$$

其中 $\bar{x},\bar{y}$ 分别为数据$\{x_i\}$,$\{y_i\}$的样本均值.

使用简单不等式$\left[\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})\right]^2\leqslant\sum_{i=1}^{n}(x_i-\bar{x})^2\sum(y_i-\bar{y})^2$,可知$|r_{xy}|\leqslant 1$.当 $r_{xy}=\pm 1$ 时,称数据极大相关;而当 $r_{xy}=0$ 时,称数据不相关.注意到:如果

$$x_i\geqslant\bar{x}\Rightarrow y_i\geqslant\bar{y},$$

$$x_i\leqslant\bar{x}\Rightarrow y_i\leqslant\bar{y},$$

则 $y$ 有随 $x$ 增大(或减少)而增大(或减少)的趋势,因此当 $r_{xy}>0$ 时,称数据对正相关;同样地,当 $r_{xy}<0$ 时,称数据对负相关.

一般来说,判断数据对的相关性,除了使用样本相关系数,还需结合散点图加以印证.散点图就是将各个数据对一一标在平面坐标纸上画出的图像.下面的图 8.2(a),图 8.2(b)分别是对应负相关和正相关的数据对的散点图.

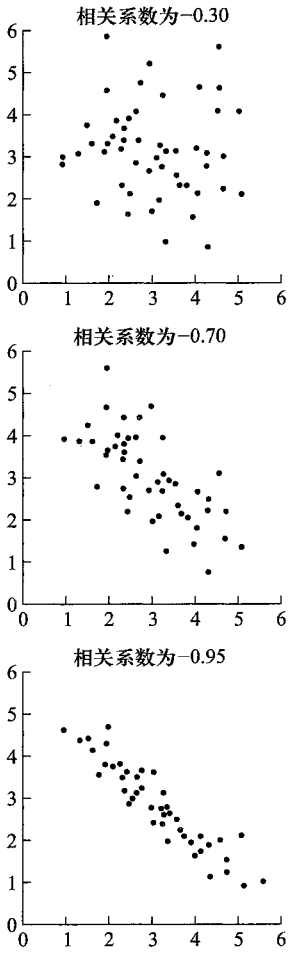
在结束本小节的时候,我们简单小结一下:当以样本均值为数据中心位置指标时,常用的统计量是 $\bar{X}$ 与 $S$;当以样本中位数为数据中心位置指标时,常用统计量为 $med$,$R$ 或 $H$.而后者同 $med,x_{(1)},x_{(n)},Q_L,Q_U$ 有关,常称之为五数概括.对于成对数据,常用的统计量为 $\bar{X},\bar{Y},S_x,S_y,r_{xy}$.

**例 6** 考查学生在网络上消耗的时间.随机调查了 30 位学生和他们每周在网络上投入的时间值如下:

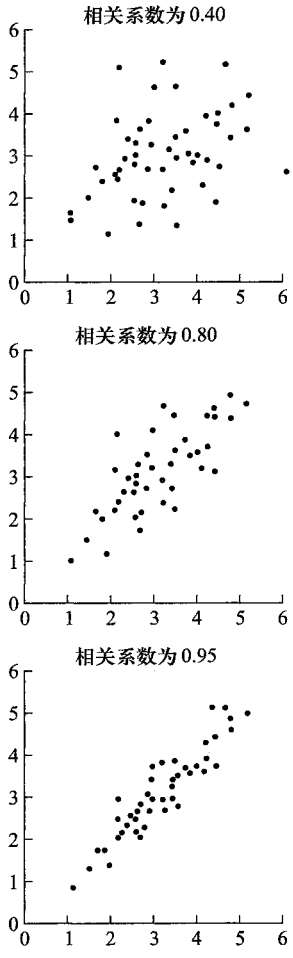
7,28,42,47,72,83,20,28,43,48,75,87,24,30,44,48,77,88,25,32,45,50,78,135,25,35,46,51,79,151,

请给出五数概括,并找出异常值.

**解** 五数概括中,最小值$x_{(1)}=7$,下四分位数$Q_L=30$,中位数 $med=46.5$,上四分位数$Q_U=77$,最大值$x_{(30)}=151$,四分位间距 $H=Q_U-Q_L=47$,$Q_L-1.5H=-40.5$,$Q_U+1.5H=147.5$.如图 8.3 所示,因为 151>147.5,所以 151 可以认为是异常值.




相关系数——三个负值，负相关情形．图中横向和纵向平均数都是3，$S$ 都是1．每个图都有50个点．




相关系数——三个正值，正相关的情形．图中横向和纵向平均数都是3，$S$ 都是1．每个图都有50个点．

图 8.2

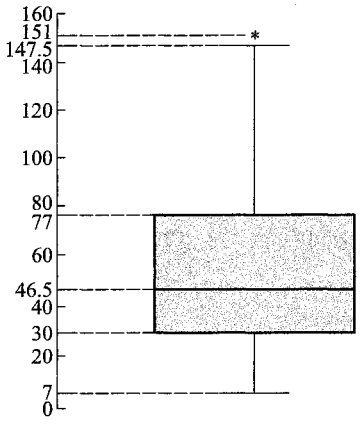



图 8.3

## 习题 8.2

1. 设 $X_1, X_2, \cdots, X_6$ 是来自 $(0,\theta)$ 上均匀分布的样本，$\theta>0$ 未知.

(1) 指出下列样本函数中哪些是统计量，哪些不是？为什么？

$$T_1=\frac{X_1+X_2+\cdots+X_6}{6}, T_2=X_6-\theta, T_3=X_6-E(X_1), T_4=\max\{X_1, X_2, \cdots, X_6\};$$

(2) 如样本的一组观测值是 0.5,1,0.7,0.6,1,1，写出样本均值，样本方差和样本标准差.

2. 某一马拉松比赛中前 30 名运动员成绩(单位:min)如下：

129,130,130,133,134,135,136,136,138,138,138,141,141,141,142,
142,142,142,143,143,143,143,143,144,144,145,145,145,145,145.

(1) 计算该 30 名运动员成绩的样本均值和样本标准差；

(2) 计算这组成绩的样本中位数；

(3) 计算这组成绩的上、下四分位数和四分位间距.

3. 已知某校本学期共有 2 000 位学生参加概率论与数理统计课程的考试，其中女生 800 名，男生 1 200 名.成绩统计如下：

| | 最低分 | 下四分位数 | 中位数 | 上四分位数 | 最高分 |
|---|---|---|---|---|---|
| 男生 | 0 | 64 | 70 | 80 | 100 |
| 女生 | 12 | 62 | 75 | 89 | 98 |

(1) 男生和女生哪一组的分数高？

(2) 男生和女生哪一组分数的差异较大？

4. 为研究训练水平与心脏血液输出量之间的关系，随机抽取 20 人，并将他们随机分成四组，每组一个训练水平，训练 15 min 后，测量他们的心脏血液输出量(单位:ml/min)，结果如下：

| 序号 | 训练水平 $x$ | 心脏血液输出量 $y/(\text{ml}\cdot\text{min}^{-1})$ | 序号 | 训练水平 $x$ | 心脏血液输出量 $y/(\text{ml}\cdot\text{min}^{-1})$ |
|---|---|---|---|---|---|
| 1 | 0 | 4.4 | 11 | 600 | 12.8 |
| 2 | 0 | 5.6 | 12 | 600 | 13.4 |
| 3 | 0 | 5.2 | 13 | 600 | 13.2 |
| 4 | 0 | 5.4 | 14 | 600 | 12.6 |
| 5 | 0 | 4.4 | 15 | 600 | 13.2 |
| 6 | 300 | 9.1 | 16 | 900 | 17.0 |
| 7 | 300 | 8.6 | 17 | 900 | 17.3 |
| 8 | 300 | 8.5 | 18 | 900 | 16.5 |
| 9 | 300 | 9.3 | 19 | 900 | 16.8 |
| 10 | 300 | 9.0 | 20 | 900 | 17.2 |

试计算样本相关系数,并由此解释训练水平与心脏血液输出量之间的相关关系.

5. 已知10家百货商店平均每人每月平均销售额和利润率,如下所示:

| 商店 | 每人每月平均销售额/万元 | 利润率/% |
|---|---|---|
| 1 | 6 | 12.6 |
| 2 | 5 | 10.4 |
| 3 | 8 | 13.5 |
| 4 | 1 | 3 |
| 5 | 4 | 8.1 |
| 6 | 7 | 16.3 |
| 7 | 6 | 12.3 |
| 8 | 3 | 6.2 |
| 9 | 3 | 6.6 |
| 10 | 7 | 16.8 |

(1) 绘制每人每月平均销售额与利润率之间的散点图;

(2) 计算每人每月平均销售额与利润率之间的相关系数;

(3) 结合散点图,分析每人每月平均销售额与利润率之间的相关关系.

## 第三节 抽样分布

所谓抽样分布,即统计量的分布.因为统计推断虽然是基于样本作出的,但任何推断都离不开一组适当的统计量,因此不如说:统计推断是直接基于统计量作出的.从而研究抽样分布是统计推断的一项十分重要的内容.由于样本均值的重要性,本节先讨论样本均值的抽样规律,再讨论在正态总体下,常用统计量的抽样分布.

### *一、有限总体的抽样分布

在大多数实际问题中,总体中个体个数是有限的,特别是对抽样调查更是如此,我们称这种总体为有限总体.此时,抽样规则对统计量的分布有很大影响.通常考虑有放回和不放回两种抽样规则.在有放回抽样情况下,样本是独立同分布的;而在不放回情况下,样本同分布但不独立,而且在实际抽样时,绝大多数是无放回抽样,这除了不放回抽样的成本低之外,还有理论上的重要原因.下面的定理显示了样本均值在这两种抽样方式下的不同表现.我们有

**定理1** 设总体中个体总数(也称总体大小)为$N$,样本容量为$n$ ($<N$)且总体有有限均值$\mu$,方差$\sigma^2$,则

(i) $E(\overline{X})=\mu$; (6)

(ii) 当抽样是有放回的时，

$$D(\bar{X})=\frac{\sigma^2}{n},\quad \sigma(\bar{X})=\frac{\sigma}{\sqrt{n}},\tag{7}$$

当抽样是不放回的时，

$$D(\bar{X})=\frac{N-n}{N-1}\cdot\frac{\sigma^2}{n},\quad \sigma(\bar{X})=\sqrt{\frac{N-n}{N-1}}\frac{\sigma}{\sqrt{n}},\tag{8}$$

其中 $\sigma(\bar{X})$ 即为 $\bar{X}$ 的标准差.

证明见附录.

下面对定理 1 的结论做些说明.首先，由(7)式和(8)式可见，样本均值的标准差至少比总体标准差缩小$\sqrt{n}$倍，因此从平均观点来说，增大样本容量可以降低抽样误差，达到控制随机误差的作用.

其次，比较(7)式和(8)式可知：当 $n>1$ 时，不放回抽样的样本均值的标准差较小，从而有较小的抽样误差，这就为使用不放回抽样的合理性找到理论根据.

最后，当 $n\ll N$，即 $n$ 比 $N$ 小得多时，(7)式与(8)式很接近，此时，可近似地将不放回抽样当作有放回抽样.

## 二、三个重要分布

为了讨论正态总体下的抽样分布，先引入由正态分布导出的统计中的三个重要分布，即$\chi^2$ 分布、$t$ 分布、$F$ 分布.

设 $X_1,X_2,\cdots,X_n$ 为相互独立的服从标准正态分布的随机变量，称随机变量

$$U=X_1^2+X_2^2+\cdots+X_n^2$$

服从自由度为 $n$ 的$\chi^2$ 分布，记为 $U\sim\chi^2(n)$，且变量 $U$ 有期望、方差：

$$E(U)=n,\ D(U)=2n.\tag{9}$$

$\chi^2(n)$分布的密度函数的图像如图 8.4(a)所示.



$\chi^2$分布

又若随机变量 $X$ 与 $Y$ 相互独立，且 $X\sim N(0,1)$，$Y\sim\chi^2(n)$，则称随机变量

$$T=\frac{X}{\sqrt{Y/n}}$$

服从自由度为 $n$ 的 $t$ 分布，记为 $T\sim t(n)$，$t(n)$分布的密度函数图像如图8.4(b)所示.



$t$分布

若随机变量 $U$ 与 $V$ 相互独立，且 $U\sim\chi^2(n)$，$V\sim\chi^2(m)$，则称随机变量

$$F=\frac{U/n}{V/m}$$

服从自由度为$(n,m)$的 $F$ 分布，记为 $F\sim F(n,m)$.$F(n,m)$分布的密度函数图像如图 8.4(c)所示.



$F$分布

注意到 $t$ 分布的密度函数图像与标准正态分布的密度函数图像类似，都关于纵轴对称，又$\chi^2$ 分布与 $F$ 分布的密度函数的自变量只取正值.这三个分布都有表可查，例如对给定的 $\alpha(0<\alpha<1)$，常用 $t_\alpha(n)$，$\chi^2_\alpha(n)$，$F_\alpha(n,m)$表示相应分布的 $\alpha$ 分位数，即它们分别满足：

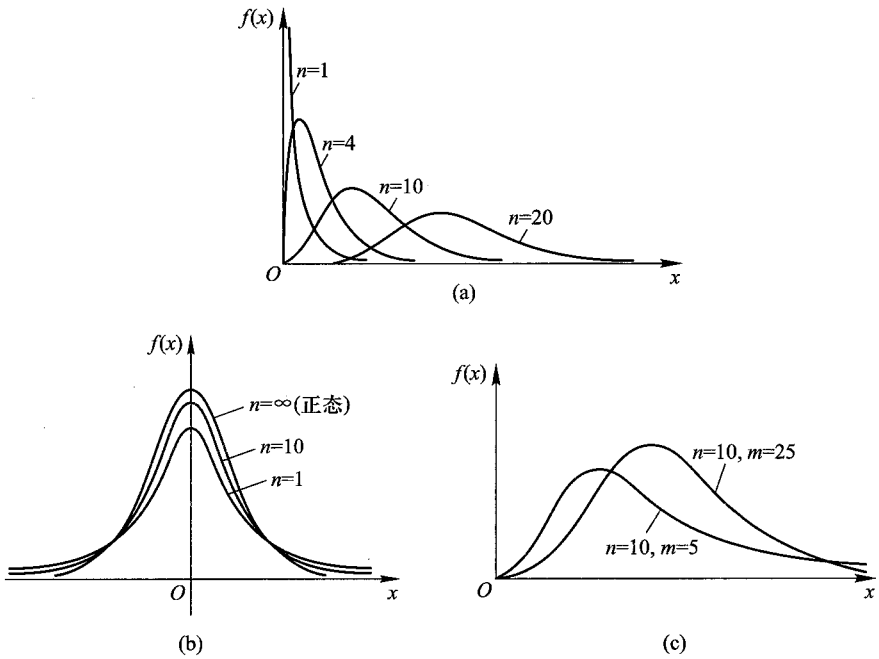



图 8.4

$$P(U\leqslant\chi_{\alpha}^{2}(n))=\alpha,$$

$$P(T\leqslant t_{\alpha}(n))=\alpha,$$

$$P(F\leqslant F_{\alpha}(n,m))=\alpha.$$

对于 $\alpha$ 的不同值,从书末附表可查到 $\alpha$ 分位数的值.由对称性易知

$$t_{1-\alpha}(n)=-t_{\alpha}(n),$$

又由 $F$ 分布定义可知

$$F_{1-\alpha}(n,m)=\frac{1}{F_{\alpha}(m,n)}.$$

这两个公式,对于查分位数表是有用的.最后要指出,$\chi^2$ 分布具有可加性,即若随机变量 $U_1,U_2,\cdots,U_m$ 相互独立,$U_i\sim\chi^2(n_i)$ $(i=1,2,\cdots,m)$,则 $U_1+U_2+\cdots+U_m\sim\chi^2(n_1+n_2+\cdots+n_m)$,此结果可由 $\chi^2$ 分布定义及归纳法加以证明,留给读者作为练习.

### 三、正态总体的抽样分布

本段假设 $X_1,X_2,\cdots,X_n$ 是来自正态总体 $N(\mu,\sigma^2)$ 的样本,即它们是独立同分布的,皆服从 $N(\mu,\sigma^2)$ 分布.

**定理 2** (i) $\bar{X}\sim N\left(\mu,\frac{\sigma^2}{n}\right)$;

(ii) $\bar{X}$ 与 $S^2=\frac{1}{n-1}\sum\limits_{i=1}^{n}(X_i-\bar{X})^2$ 相互独立;

(iii) $\dfrac{(n-1)S^2}{\sigma^2}\sim\chi^2(n-1)$,

其中 $S^2$ 为样本方差.(证明从略.)

通常 $S^2$ 可用作总体方差 $\sigma^2$ 的估计,它与 $S,\bar{X}$ 构成最常用的统计量.由定理 2 的结论(i)知:样本均值 $\bar{X}$ 有很好的性质,它的分布以总体均值 $\mu$ 为对称中心,但分散程度是总体的 $\dfrac{1}{n}$,也就是说,如以 $\bar{X}$ 作为 $\mu$ 的估计,其估计精度要比用单个样本 $X_1$ 做估计要高 $n$ 倍.结论(ii)表明:在正态总体情形,两个重要统计量 $S^2$ 与 $\bar{X}$ 是相互独立的;结论(iii)表明,对正态总体来说,总体方差的估计 $S^2$ 经过适当的变换后,其分布为 $\chi^2(n-1)$,这对总体方差的统计推断是重要的.

该定理是正态总体统计推断的基础,因而是十分重要的,下面列举其应用.

**例 7** 设 $X_1,X_2,\cdots,X_n$ 是来自正态总体 $N(\mu,\sigma^2)$ 的样本,则随机变量

$$T=\frac{\bar{X}-\mu}{\sqrt{S^2/n}}\sim t(n-1).$$

**证** 令 $X=\dfrac{\sqrt{n}(\bar{X}-\mu)}{\sigma}$,$Y=\dfrac{(n-1)S^2}{\sigma^2}$,则由定理 2 知 $X\sim N(0,1)$,$Y\sim\chi^2(n-1)$,且 $X$ 与 $Y$ 相互独立.由 $T=\dfrac{X}{\sqrt{Y/(n-1)}}$ 及 $t$ 分布定义即知 $T\sim t(n-1)$.

**例 8** 设 $X_1,X_2,\cdots,X_m$ 与 $Y_1,Y_2,\cdots,Y_n$ 是分别来自正态总体 $N(\mu_1,\sigma^2)$ 与 $N(\mu_2,\sigma^2)$ 的两个独立的样本,记

$$\bar{X}=\frac{1}{m}\sum_{i=1}^{m}X_i,\ \bar{Y}=\frac{1}{n}\sum_{i=1}^{n}Y_i,$$

$$S_X^2=\frac{1}{m-1}\sum_{i=1}^{m}(X_i-\bar{X})^2,\ S_Y^2=\frac{1}{n-1}\sum_{j=1}^{n}(Y_j-\bar{Y})^2,$$

$$S_w^2=\frac{(m-1)S_X^2+(n-1)S_Y^2}{m+n-2},$$

则随机变量

$$T=\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sqrt{\dfrac{1}{m}+\dfrac{1}{n}}\cdot S_w}\sim t(m+n-2).$$

**证** 使用 $\chi^2$ 变量的可加性及定理 2 的(iii)知

$$U=\frac{(m+n-2)S_w^2}{\sigma^2}\sim\chi^2(m+n-2),$$

又令

$$V=\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sigma\sqrt{\dfrac{1}{m}+\dfrac{1}{n}}},$$

典型例题精讲视频

抽样分布综合例题

由定理 2 的(i)知 $V\sim N(0,1)$.再使用定理 2 的(ii)可知:$\bar{X}$ 与 $S_X^2$ 相互独立,$\bar{Y}$ 与 $S_Y^2$ 相互独立,且因 $X_1,X_2,\cdots,X_m$ 与 $Y_1,Y_2,\cdots,Y_n$ 相互独立,所以 $\bar{X}$ 与 $S_Y^2$ 相互独立,$\bar{Y}$ 与 $S_X^2$ 相互独立,因而 $(\bar{X},\bar{Y})$ 与 $(S_X^2,S_Y^2)$ 相互独立,由此即知 $U$ 与 $V$ 相互独立.最后,由 $T=\dfrac{V}{\sqrt{U/(m+n-2)}}$ 及 $t$ 分布定义即知 $T\sim t(m+n-2)$.

**例 9**(例 8 续)

$$F=\frac{S_X^2}{S_Y^2}\sim F(m-1,n-1).$$

此例的证明留给读者作为练习.

*除了正态总体等少数例外,对一般总体,精确的抽样分布多不易得到,为此常借助极限分布.

当一个统计量存在极限分布时,可用此极限分布作为近似的抽样分布,并称此极限分布为统计量的渐近分布,一类最重要的极限分布可通过中心极限定理导出.

设总体 $X$ 有有限均值 $\mu$ 及方差 $\sigma^2$,$X_1,X_2,\cdots,X_n$ 是样本,则由中心极限定理,当 $n\to\infty$,有

$$\frac{\sqrt{n}(\bar{X}-\mu)}{\sigma}\overset{\text{近似}}{\sim}N(0,1),$$

因此统计量 $\bar{X}$ 有渐近分布 $N\left(\mu,\dfrac{\sigma^2}{n}\right)$.

**例 10** 某镇有 25 000 户家庭,平均每户拥有汽车 1.2 辆,标准差为 0.90 辆,它们中 10%没有汽车.今有 1 600 户家庭的随机样本,问在样本中 9%和 11%之间的家庭没有汽车的概率是多少?

**解** 今引入新变量

$$X_i=\begin{cases}1, & \text{第 } i \text{ 个样本家庭无汽车},\\ 0, & \text{第 } i \text{ 个样本家庭有汽车}\end{cases}\quad(i=1,2,\cdots,n,n=1\ 600).$$

按假设条件,$p=P(X_i=1)=0.10$,因 $n\ll N$ $(N=25\ 000)$,故可以近似地看成有放回抽样,$X_1,X_2,\cdots,X_n$ 相互独立.分别以 $\mu,\sigma$ 记 $X_1,X_2,\cdots,X_n$ 的公共均值和标准差,则由假设知 $\mu=0.10$,$\sigma=\sqrt{0.10\times0.90}=0.3$,样本中无汽车家庭的比率即为 $\bar{X}$,由于 $n=1\ 600$ 较大,可以使用渐近分布求解,即 $\bar{X}\sim N\left(\mu,\dfrac{\sigma^2}{n}\right)$,所求概率即为

$$\begin{aligned}&P(9\%\leqslant\bar{X}\leqslant11\%)\\&=P\left(\frac{40(0.09-0.10)}{0.3}\leqslant\frac{\sqrt{n}(\bar{X}-\mu)}{\sigma}\leqslant\frac{40(0.11-0.10)}{0.3}\right)\\&\approx\Phi\left(\frac{40(0.11-0.10)}{0.3}\right)-\Phi\left(\frac{40(0.09-0.10)}{0.3}\right)\\&=2\Phi\left(\frac{0.4}{0.3}\right)-1=2\times0.908\ 2-1=0.816\ 4.\end{aligned}$$

## 习题 8.3

1. 设$(X_1,X_2,\cdots,X_n)$是取自总体$X$的一个样本,在下列三种情况下,分别求$E(\bar{X})$,$D(\bar{X})$,$E(S^2)$:

(1) $X\sim B(1,p)$;(2) $X\sim E(\lambda)$;(3) $X\sim R(0,2\theta)$,其中$\theta>0$.

2. 设$(X_1,X_2,\cdots,X_n)$是取自总体$N(1,\sigma^2)$的一个样本,求:

(1) $E\left[\sum\limits_{i=1}^{n}(X_i-1)^2\right]$,$D\left[\sum\limits_{i=1}^{n}(X_i-1)^2\right]$;(2) $E\left[\left(\sum\limits_{i=1}^{n}X_i-n\right)^2\right]$,$D\left[\left(\sum\limits_{i=1}^{n}X_i-n\right)^2\right]$.

3. 查表求$\chi^2_{0.99}(12)$,$\chi^2_{0.01}(12)$,$t_{0.99}(12)$,$t_{0.01}(12)$,$F_{0.99}(1,12)$,$F_{0.01}(1,12)$.

4. 设$T\sim t(10)$,求常数$c$使$P(T>c)=0.95$.

5. 设$X_1,X_2,\cdots,X_5$是相互独立且服从相同分布的随机变量,且每一个$X_i(i=1,2,\cdots,5)$都服从$N(0,1)$.

(1) 试给出常数$c$,使得$c(X_1^2+X_2^2)$服从$\chi^2$分布,并指出它的自由度;

(2) 试给出常数$d$,使得$d\dfrac{X_1+X_2}{\sqrt{X_3^2+X_4^2+X_5^2}}$服从$t$分布,并指出它的自由度;

(3) 试给出常数$k$,使得$k\dfrac{X_1^2+X_2^2}{X_3^2+X_4^2+X_5^2}$服从$F$分布,并指出它的自由度.

6. 设$X_1,X_2,\cdots,X_5$是来自正态总体$N(0,\sigma^2)$的样本,试证:

(1) $\dfrac{1}{\sigma^2}\sum\limits_{i=1}^{n}X_i^2\sim\chi^2(n)$;

(2) $\dfrac{1}{n\sigma^2}\left(\sum\limits_{i=1}^{n}X_i\right)^2\sim\chi^2(1)$.

*7. 某市有100 000个年满18岁的居民,他们中10%年收入超过20万,20%受过高等教育.今从中抽取1 600人的随机样本,求

(1) 样本中不少于11%的人年收入超过20万的概率;(2) 样本中19%和21%之间的人受过高等教育的概率.

## 附 录

定理1的证明:由$X_1,X_2,\cdots,X_n$与$X$同分布知,

$$E(X_i)=E(X)=\mu,\ i=1,2,\cdots,n,$$

从而$E(\bar{X})=\dfrac{1}{n}\sum\limits_{i=1}^{n}E(X_i)=\mu$,得证(6)式.

又在有放回抽样时,$X_1,X_2,\cdots,X_n$是独立同分布的,因而

$$D(\bar{X})=\frac{1}{n^2}\sum_{i=1}^{n}D(X_i)=\frac{\sigma^2}{n}.$$

两边开平方,即得证(7)式.

再考虑无放回的情况,记总体$X$的取值为$a_1,a_2,\cdots,a_N$,由抽样的随机性有,抽到任一个体的概率都为$\dfrac{1}{N}$,而抽到任意两个指定个体的概率为$\dfrac{1}{N(N-1)}$.因而

$$\mu = E(X) = \frac{1}{N}\sum_{i=1}^{N} a_i = \bar{a},$$

$$\sigma^2 = D(X) = E[(X-\mu)^2] = \frac{1}{N}\sum_{i=1}^{n} (a_i - \bar{a})^2.$$

对任意 $1 \leqslant i \neq j \leqslant n$ 有

$$\begin{aligned}\operatorname{cov}(X_i, X_j) &= E[(X_i - \mu)(X_j - \mu)] \\ &= \frac{1}{N(N-1)}\sum_{s \neq t} (a_s - \bar{a})(a_t - \bar{a}) \\ &= \frac{1}{N(N-1)}\left[\sum_{s=1}^{N}\sum_{t=1}^{N} (a_s - \bar{a})(a_t - \bar{a}) - \sum_{t=1}^{N} (a_t - \bar{a})^2\right].\end{aligned}$$

注意到 $\sum_{s=1}^{N} (a_s - \bar{a}) = 0$,因此

$$\operatorname{cov}(X_i, X_j) = -\frac{1}{(N-1)}\frac{1}{N}\sum_{t=1}^{N} (a_t - \bar{a})^2 = -\frac{\sigma^2}{N-1} \quad (1 \leqslant i \neq j \leqslant n),$$

于是

$$\begin{aligned}D(\bar{X}) &= \frac{1}{n^2} D\left(\sum_{i=1}^{n} X_i\right) \\ &= \frac{1}{n^2}\left[\sum_{i=1}^{n} D(X_i) + 2\sum_{i<j} \operatorname{cov}(X_i, X_j)\right] \\ &= \frac{1}{n^2}\left(n\sigma^2 - 2\sum_{i<j} \frac{\sigma^2}{N-1}\right) \\ &= \frac{N-n}{N-1}\frac{\sigma^2}{n},\end{aligned}$$

得证(8)式,定理证毕.

## 小　结

统计研究对象是大量社会经济和自然现象的一定总体的数量特征及数量关系.所谓总体即研究对象的全体,或服从一定分布的研究对象的统计指标.总体中按一定规则抽出的一部分个体为样品,样品的统计指标为样本.简单随机样本是一组互相独立的与总体有相同分布的随机变量.

统计学是使用有效方法收集数据、分析数据,并基于数据作出推断的一门方法论科学,它的主要内容包括抽样调查、试验设计、点估计、区间估计和假设检验等.

完全由样本确定的量称为统计量,它是样本的函数.常用的统计量有样本均值 $\bar{X}$,样本方差 $S^2$,样本标准差 $S$,样本相关系数 $r_{xy}$ 以及样本中位数.

当总体为正态分布 $N(\mu, \sigma^2)$ 时,有

(i) $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$; (ii) $\bar{X}$ 与 $S^2$ 独立; (iii) $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$,

这是正态总体抽样的基本定理.

## 第八章综合题

1. 设$(X_1,X_2,\cdots,X_n)$是取自总体$X$的一个样本,$\bar{X},S$分别为样本均值和样本标准差,在下列两种总体分布的假定下,分别求$E(\bar{X}),D(\bar{X}),E(S^2)$.

(1) $X\sim P(\lambda)$;(2) $X\sim N(\mu,\sigma^2)$;(3) $X\sim\chi^2(n)$.

2. 设$(X_1,X_2,X_3,X_4,X_5,X_6)$是取自正态总体$N(1,\sigma^2)$的样本,$\bar{X},S$分别为样本均值和样本标准差,求$P(\bar{X}>1),P(\bar{X}<1,S^2<1.847\,2\sigma^2)$.

典型例题精讲视频

单正态总体下的抽样分布

** 3. 设随机变量$X\sim t(n),Y\sim F(1,n)$,给定$\alpha(0<\alpha<0.5)$,常数$c$满足$P(X>c)=\alpha$,求$P(Y>c^2)$.

4. 设$(X_1,X_2,X_3)$为来自正态总体$N(1,\sigma^2)$的样本,求统计量$\dfrac{X_1-X_2}{\sqrt{2}\,|X_3-1|}$服从的分布.

5. 设$(X_1,X_2,\cdots,X_5)$是取自正态总体$N(0,\sigma^2)$的一个样本,$F=c\dfrac{(X_1+X_2+X_3)^2}{(X_4+X_5)^2}$,其中$c$为非零常数,问$F$服从什么分布,自由度是多少,$c$是多少?

** 6. 设$(X_1,X_2,\cdots,X_n)$是取自总体$N(0,1)$的一个样本,$\bar{X}$为样本均值,$S^2$为样本方差,求下列统计量的分布:

(1) $\sqrt{n}\bar{X}$;(2) $(n-1)S^2$;(3) $\sqrt{n}\dfrac{\bar{X}}{S}$;(4) $\dfrac{(n-1)X_1^2}{\sum\limits_{i=2}^{n}X_i^2}$.

## 第八章自测题

## 第八章习题参考答案