*第十二章 一元线性回归

本章涉及数理统计学中应用极为广泛的一个分支，即统计回归分析.虽然一元线性回归仅仅是其中一小部分，但一则，由于其结构简单，可作为学习一般回归分析的入门；二则，由于一元线性回归的展开，涉及从点估计到假设检验和置信区间等一套完整的统计方法，因而可以说是前面几章介绍的一般统计方法的应用.

第一节 若干基本概念

在现实世界中有许多变量，它们的出现是相互关联的，但并不存在严格的确定性关系.我们先看一个例子：

例 1 文献上曾报道一项年龄和死亡率之间的研究，其中 x=年龄(单位：岁)，Y=ln(死亡率/(1-死亡率))，Y 是对死亡率(单位：‰)作了逻辑斯谛(logistic)变换后的数值①.

年龄	死亡率	ln(死亡率/(1-死亡率))	年龄	死亡率	ln(死亡率/(1-死亡率))
17	0.000 421	-7.772 456 7	47	0.002 368	-6.043 338 817
22	0.000 533	-7.536 456 1	52	0.003 938	-5.533 136 582
27	0.000 601	-7.416 314 5	57	0.006 479	-5.032 689 074
32	0.000 753	-7.190 692 1	62	0.011 196	-4.480 939 607
37	0.001 066	-6.842 775 5	67	0.019 306	-3.927 844 597
42	0.001 534	-6.478 341 5	72	0.068 857	-2.604 381 001

其散点图见图 12.1：

从数据中可看到，Y 与 x 虽有一定关联，但并不存在如数学上的函数关系那样的确定性关系.Y 值并不能由 x 所完全确定，而是还存在其他的不确定因素；又当 x 增大时，Y 的走向有很强的趋势，即 Y 随着 x 增加而增大，因此 Y 与 x 有正相关的关系.回归分析就是研究这样一对变量之间不确定性数量关系的统计规律.

① 本例数据来自参考文献[10].

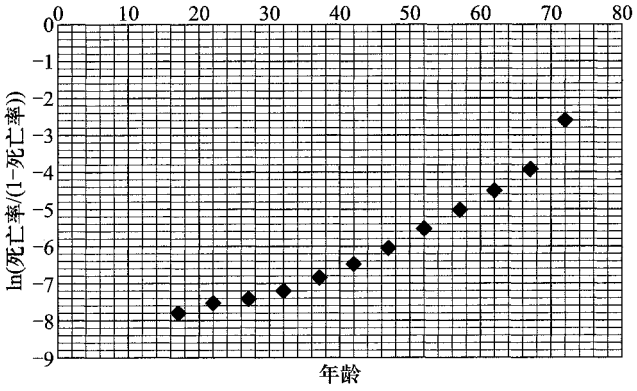


图 12.1

一、解释变量和响应变量

假设两个变量之间存在关联,但并非确定性关系,其中一个是可以控制或给定的,我们称之为解释变量或自变量,记之为 x;另一个变量是随机的,其取值可以观测,我们称之为响应变量或因变量,记之为 Y,其观测值用小写字母 y 记之.

通常观测是对自变量的许多设定的值(例如记为 $x_1, x_2, \cdots, x_n$)作出的,令 Y_i 记在给定 x 为 x_i 时对响应变量 Y 的观测,而记其观测值为 y_i,这样就得到由 n 个对子 $(x_1, y_1), (x_2, y_2), \cdots, (x_n, y_n)$ 组成的有效数据.分别将它们标在二维坐标系中,得到一张由 n 个点组成的散点图.

例 2 研究儿童的睡眠时间与年龄的关系.下面是 13 个健康儿童的数据①,其中睡眠时间 Y 是使用相继 3 个晚上的睡眠时间的平均(单位:min),x 为年龄(单位:岁):

年龄 x	儿童睡眠时间 Y	年龄 x	儿童睡眠时间 Y
4.4	586	8.9	515.2
14	461.75	11.1	493
10.1	491.1	7.75	528.3
6.7	565	5.5	575.9
11.5	462	8.6	532.5
9.6	532.1	7	530.5
12.4	477.6		

其散点图见图 12.2:

散点图作为回归分析的前期工作是非常必要的,它可以对变量之间关系的取向提供直观的判断.

① 本例数据来自参考文献[9].

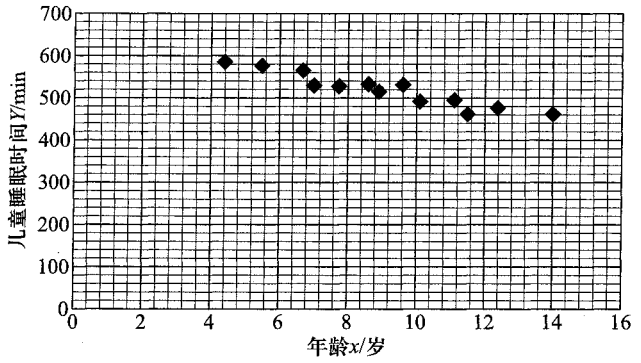


图 12.2

注意到,在有些实际问题中,作为考察对象的两个指标 x 与 Y 可能都是随机的,例如为考察父子身高的关联性,在某个范围内的所有家庭中,随机抽取一户,然后观测其父子的身高,x 为父亲的身高,Y 为儿子的身高.此时,变量 x 与 Y 都是随机的,它们的取值只能观测,不能给定.对于这种情况的处理同我们这里讨论的情况稍有不同,有兴趣的读者可参看有关的书籍.

二、线性回归的概率模型

假定响应变量 Y 在给定 x 时的期望值是 x 的一元线性函数 $a+bx$,且 Y 与该期望值相差一个随机变量 ε,我们称之为随机误差,因此,我们可以用下述模型描述 x 与 Y 之间的关系:

$$Y=a+bx+\varepsilon. \tag{1}$$

此外,我们还假定模型(1)满足下述条件:对任意给定的 x,

(i) ε 服从正态分布;

(ii) ε 的均值为零,方差为 σ^2.

通常都要在 x 的给定的 n 个水平 $x_1,x_2,\cdots,x_n$ 上,对响应变量 Y 作 n 次独立观测,依次得到 $y_1,y_2,\cdots,y_n$,因此样本 $(x_1,y_1),(x_2,y_2),\cdots,(x_n,y_n)$ 满足

$$y_i=a+bx_i+\varepsilon_i,i=1,2,\cdots,n, \tag{2}$$

其中 $\{\varepsilon_i\}$ 为随机误差序列,由于观测是独立进行的,因此模型(2)满足

(iii) $\varepsilon_1,\varepsilon_2,\cdots,\varepsilon_n$ 相互独立,且与 ε 有相同分布.

我们称满足假设条件(i)—(iii)的模型(2)为一元线性回归模型,而称满足条件(i)—(ii)的模型(1)为理论模型.

依假设可知,对给定 x,有

$$E(Y|x)\hat{=}a+bx,$$

$$D(Y|x)=\sigma^2,$$

其中 $E(Y|x)$ 及 $D(Y|x)$ 分别表示给定自变量为 x 时,Y 的期望和方差.并称

$$y=a+bx \tag{3}$$

为真回归直线，a 为截距，b 为回归系数.从模型(2)可知由于随机误差项的存在，诸观测样本(x_i,y_i)，$i=1,2,\cdots,n$ 并不是正好落在真回归直线上，而是与之有或多或少的偏差.记 $\mu(x)=E(Y\mid x)$，则 $\mu(x)$ 表示当给定 x 时，所有可能的 y 值的平均，文献上也称之为回归函数；而 σ^2 则是所有可能的 y 值围绕平均值 $\mu(x)$ 的散布程度.注意到 σ 与 x 无关，也称这个性质为方差齐次性.

在实际问题中，真回归直线总是未知的，因此确定真回归直线是回归分析必须首先解决的一个问题.此外，在模型(2)中，还有一个未知参数 σ^2，需要估计.

这里要顺便指出的是：由于诸$\{x_i\}$一般来说不尽相同，不能由假定(iii)推出诸$\{y_i\}$有相同分布.也就是说线性回归模型的响应变量的观测样本 $y_1,y_2,\cdots,y_n$ 是相互独立的，但是不同分布.这是该模型的一个重要特征.

三、最小二乘回归

现设已有来自总体(x,Y)的观测数据$(x_1,y_1),(x_2,y_2),\cdots,(x_n,y_n)$，基此确定 x 与 Y 的线性回归关系，或者说，确定回归直线(3)，即基于数据，估计回归参数 a 及 b，记其估计为$\hat{a},\hat{b}$，则$\hat{y}=\hat{a}+\hat{b}x$，即是其回归直线的一种估计，或者说一种确认.然而，基于给定的数据集，可以构造无数条可能的直线，究竟用哪一条估计真回归直线呢？直观上，所选择的直线应该提供在某种意义上对观测数据的最佳拟合.德国数学家高斯(Gauss，1777—1855)提出过一种称之为最小二乘原理的准则：一个好的拟合直线应该使得观测点到拟合直线的垂直方向的偏差平方和达到最小.

事实上，一条拟合直线 $y=a+bx$ 与数据集$\{(x_i,y_i),i=1,2,\cdots,n\}$的接近程度可以用一个称之为偏差(如图 12.3)平方和的指标

$$Q(a,b)=\sum_{i=1}^{n}[y_i-(a+bx_i)]^2$$

来度量，因此最佳拟合直线应使偏差平方和 Q 达到最小，我们也称这样的拟合直线为最小二乘回归直线.

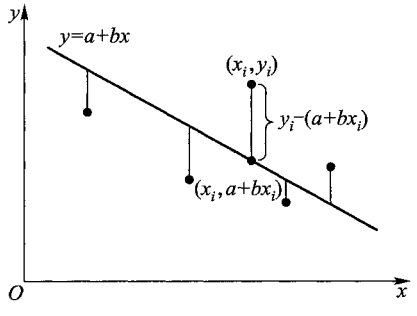


图 12.3　观测点与拟合直线沿垂直方向的偏差

由高等数学中求函数极值的知识可知，使得偏差平方和达到最小的解可以通过求解以下方程得到：

$$\begin{cases} \dfrac{\partial Q}{\partial a} = -2\sum\limits_{i=1}^{n}(y_i - a - bx_i) = 0, \\ \dfrac{\partial Q}{\partial b} = -2\sum\limits_{i=1}^{n}(y_i - a - bx_i)x_i = 0. \end{cases}$$

经过简单的代数运算,可以得到其解(记为$\hat{a},\hat{b}$)为

$$\hat{a} = \bar{y} - \hat{b}\bar{x},$$

$$\hat{b} = \frac{S_{xy}}{S_{xx}} \triangleq \frac{\sum\limits_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum\limits_{i=1}^{n}(x_i - \bar{x})^2} = \frac{\sum\limits_{i=1}^{n}x_iy_i - n(\bar{x}\ \bar{y})}{\sum\limits_{i=1}^{n}x_i^2 - n(\bar{x})^2}, \tag{4}$$

此处,$\bar{x} = \dfrac{1}{n}\sum\limits_{i=1}^{n}x_i$, $\bar{y} = \dfrac{1}{n}\sum\limits_{i=1}^{n}y_i$,

$$S_{xx} = \sum_{i=1}^{n}(x_i - \bar{x})^2, \quad S_{xy} = \sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^{n}x_iy_i - n(\bar{x}\ \bar{y}).$$

相应地,最小二乘回归直线为$\hat{y} = \hat{a} + \hat{b}x$.

以下记最小二乘回归直线对应的偏差平方和为

$$SSE = \sum_{i=1}^{n}(y_i - \hat{a} - \hat{b}x_i)^2 = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2, \tag{5}$$

其中$\hat{y}_i = \hat{a} + \hat{b}x_i$,文献上也称 *SSE* 为残差平方和.

例 3(例 2 续)　由儿童的睡眠时间与年龄关系的数据,可知:

$$n = 13, \quad \bar{x} = 9.042\ 308, \quad \bar{y} = 519.303\ 8,$$

$$\sum_{i=1}^{13}x_i^2 = 1\ 156.123, \quad \sum_{i=1}^{13}x_iy_i = 59\ 744.27, \quad \sum_{i=1}^{13}y_i^2 = 3\ 525\ 918,$$

使用公式(4)可以计算出回归系数 b 及截距 a 的估计:

$$\hat{b} = \frac{S_{xy}}{S_{xx}} = \frac{59\ 744.27 - 13\times 9.042\ 308\times 519.303\ 8}{1\ 156.123 - 13\times 9.042\ 308^2} = -\frac{1\ 299.893\ 8}{93.199\ 7} = -13.947\ 4,$$

$$\hat{a} = 519.303\ 8 - (-13.947\ 4)\times 9.042\ 308 = 645.420\ 5,$$

因此最小二乘回归直线为

$$\hat{y} = 645.420\ 5 - 13.947\ 4x,$$

也就是说儿童的年龄增加一岁,其睡眠时间减少 13.947 4 min.

例 4　以下是历史上某日单颗钻石质量 x(单位:克拉)与单颗钻石价格 Y(单位:元)的样本数据①:

① 本例数据来自参考文献[10].

编号	单颗钻石质量 x/克拉	单颗钻石价格 Y/元	编号	单颗钻石质量 x/克拉	单颗钻石价格 Y/元	编号	单颗钻石质量 x/克拉	单颗钻石价格 Y/元
1	0.17	355	17	0.12	223	33	0.32	919
2	0.16	328	18	0.26	663	34	0.15	298
3	0.17	350	19	0.25	750	35	0.16	339
4	0.18	325	20	0.27	720	36	0.16	338
5	0.25	642	21	0.18	468	37	0.23	595
6	0.16	342	22	0.16	345	38	0.23	553
7	0.15	322	23	0.17	352	39	0.17	345
8	0.19	485	24	0.16	332	40	0.33	945
9	0.21	483	25	0.17	353	41	0.25	655
10	0.15	323	26	0.18	438	42	0.35	1 086
11	0.18	462	27	0.17	318	43	0.18	443
12	0.28	823	28	0.18	419	44	0.25	678
13	0.16	336	29	0.17	346	45	0.25	675
14	0.2	498	30	0.15	315	46	0.15	287
15	0.23	595	31	0.17	350	47	0.26	693
16	0.29	960	32	0.32	918	48	0.15	316

其散点图如图 12.4 所示.

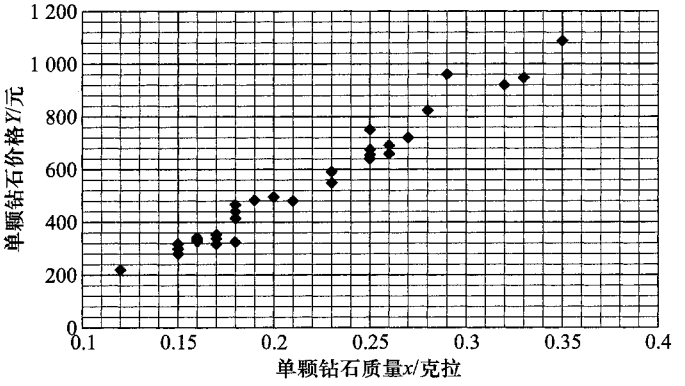


图 12.4

从其散点图可见用一根直线拟合 x 与 Y 之间的关系是比较合理的,下面我们计算最小二乘回归直线.在此

$$n = 48, \quad \sum_{i=1}^{48} x_i = 9.8, \quad \sum_{i=1}^{48} y_i = 24\ 104,$$

$$S_{xx}=\sum_{i=1}^{48}(x_i-\bar{x})^2=0.151\ 6,\quad S_{xy}=\sum_{i=1}^{48}(x_i-\bar{x})(y_i-\bar{y})=572.566\ 7$$

$$\hat{b}=\frac{S_{xy}}{S_{xx}}=\frac{572.566\ 7}{0.151\ 6}=3\ 776.825$$

$$\hat{a}=\bar{y}-\hat{b}\bar{x}=502.166\ 7-3\ 776.825\times 0.204\ 167=-268.936,$$

因此最小二乘直线为

$$y=-268.936+3\ 776.825x$$

也就是说,当单颗钻石质量每增加 0.1 克拉时,价格增加 377.68 元.

最小二乘直线可以直接用于二个目的:(1) 估计对给定 x,所有可能 Y 值的平均,也即 $E(Y\mid x)$;(2) 对一个新的试验点 x^*,预报相应的响应变量值 y^*.

在例 3 中,可以预测年龄为 $x^*=7.5$ 岁的儿童的睡眠时间为 $y^*=645.420\ 5-13.947\ 4\times 7.5=540.815$ min;在例 4 中,预测一颗重 0.3 克拉的钻石的价格均值为 $-268.936+3\ 776.825\times 0.3=864.11$ 元.

这里须指出的是,这两个方面的应用,其实际意义是大不相同的.在前者,是指对给定解释变量的值为 x_0 的响应变量的所有可能值总体的平均,具体来说,因 $E(Y\mid x)=a+bx$,实际上要估计的是未知参数 a 及 b.后者则是关心解释变量值为 x_0 的某个个体的响应变量值 y_0 是多少,它是由两个部分构成:一是均值 $a+bx_0$,另一部分是误差项 ε_0,因此预测对象是随机变量.

习题 12.1

1. 根据 100 对 (x_i,y_i) 的观察值计算出 $\sum_{i=1}^{100}(x_i-\bar{x})^2=12$, $\sum_{i=1}^{100}(x_i-\bar{x})(y_i-\bar{y})=-9$, $\sum_{i=1}^{100}(y_i-\bar{y})^2=30$.试求出一元模型 $y=a+bx+\varepsilon$ 中 a 和 b 的最小二乘估计量 $\hat{a}$ 和 $\hat{b}$.

2. 现有 10 个 18 岁成年女性的身高 x(单位:cm)和体重 y(单位:kg)的数据如下:

序号	身高 x/cm	体重 y/kg	序号	身高 x/cm	体重 y/kg
1	169.6	71.2	6	165.5	52.4
2	166.8	58.2	7	166.7	56.8
3	157.1	56	8	156.5	49.2
4	181.1	64.5	9	168.1	55.6
5	158.4	53	10	165.3	77.8

假定体重服从正态分布.

(1) 构造体重 y 关于身高 x 的散点图,该散点图是否提示两者之间存在线性关系?

(2) 给出体重 y 关于身高 x 的最小二乘回归直线.

3. 考察修理(服务)时间(单位:min)与计算机中需要修理或更换的元件个数的关系.现有一组修理记录数据如下:

序号	修理时间 y/min	元件个数 x	序号	修理时间 y/min	元件个数 x
1	23	1	8	97	6
2	29	2	9	109	7
3	49	3	10	119	8
4	64	4	11	149	9
5	74	4	12	145	9
6	87	5	13	154	10
7	96	6	14	166	10

假定修理时间服从正态分布.

(1) 构造修理时间 y 关于修理的元件个数 x 的散点图,该散点图是否提示两者之间存在线性关系?

(2) 给出修理时间 y 关于修理的元件个数 x 的最小二乘回归直线.

4. 假定一保险公司希望确定居民住宅火灾造成的损失数额与住户到最近的消防站的距离之间的相关关系,以便准确地定出保险金额.下表给出了 15 起火灾事故的损失及火灾发生地与最近的消防站的距离:

序号	距消防站距离 x/km	火灾损失 y/千元	序号	距消防站距离 x/km	火灾损失 y/千元
1	3.4	26.2	9	2.6	19.6
2	1.8	17.8	10	4.3	31.3
3	4.6	31.3	11	2.1	24
4	2.3	23.1	12	1.1	17.3
5	3.1	27.5	13	6.1	43.2
6	5.5	36	14	4.8	36.4
7	0.7	14.1	15	3.8	26.1
8	3	22.3			

假定火灾损失数额服从正态分布.

(1) 构造火灾损失 y 关于距消防站距离 x 的散点图,该散点图是否提示两者之间存在线性关系?

(2) 给出火灾损失 y 关于距消防站距离 x 的最小二乘回归直线.

5. 一家保险公司十分关心其总公司营业部加班的情况,决定认真调查一下现状.经过 10 周时间,收集了每周加班工作时间的数据和签发的新保单数目,x 为每周签发的新保单数目,y 为每周加班工作时间(单位:h)(假定每周加班时间服从正态分布).

序号	x	y/h	序号	x	y/h
1	825	3.5	6	920	3
2	215	1	7	1 350	4.5
3	1 070	4	8	325	1.5
4	550	2	9	670	3
5	480	1	10	1 215	5

(1) 构造每周加班工作时间 y 关于每周签发的新保单数目 x 的散点图,该散点图是否提示两者之间存在线性关系?

(2) 给出每周加班工作时间 y 关于每周签发的新保单数目 x 的最小二乘回归直线.

6. 为研究某一大都市报刊开设周日版的可行性,获得了 35 种报纸的平日和周日的发行量信息(单位:千).数据如下表所示:

序号	平日发行量 x/千	周日发行量 y/千	序号	平日发行量 x/千	周日发行量 y/千
1	391.952	488.506	19	781.796	983.240
2	516.981	798.198	20	1 209.225	1 762.015
3	355.628	235.084	21	825.512	960.308
4	238.555	299.451	22	223.748	284.611
5	391.952	488.506	23	354.843	407.760
6	537.780	559.093	24	515.523	982.663
7	733.775	1 133.249	25	220.465	557.000
8	198.832	348.744	26	337.672	440.923
9	252.624	417.779	27	197.120	268.060
10	206.204	344.522	28	133.239	262.048
11	231.177	323.084	29	374.009	432.052
12	449.755	620.752	30	273.844	338.355
13	288.571	423.305	31	570.364	704.322
14	185.736	202.614	32	391.286	585.681
15	1 164.388	1 531.527	33	201.860	267.781
16	444.581	553.479	34	321.626	408.343
17	412.871	685.975	35	838.902	1 165.567
18	272.280	324.241			

假定周日发行量服从正态分布.

(1) 构造周日发行量 y 关于平日发行量 x 的散点图,该散点图是否提示两者之间存在线性关系?

(2) 给出周日发行量 y 关于平日发行量 x 的最小二乘回归直线.

7. 回归一词是英国统计学家高尔顿(F. Galton, 1822—1911)和他的学生皮尔逊(K. Pearson, 1856—1936)在研究父母身高与其子女身高的遗传问题时提出的.他们观察了 928 对夫妇,以每对夫妇的平均身高作为自变量 x,而取他们的一个成年儿子的身高作为因变量 y,他们发现:虽然高个子的先代会有高个子的后代,但子代的身高并不与其父代身高趋同,而是趋向于比他们的父代更加平均,就是说如果父亲身材高大而大大高于平均值,则子代的身材要比父代矮小一些;如果父亲身材矮小而大大低于平均值,则子代的身材要比父代高大一些.换言之,子代的身高有向平均值靠拢的趋向.因此,他用回归一词来描述子代身高与父代身高的这种关系.尽管"回归"这个名称的由来具有其特定的含义,人们在研究大量的问题中变量 x 与 y 之间的关系并不总是具有"回归"的含义,但用这个名词来表示 x 与 y 之间的统计关系也是对高尔顿这位伟大的统计学家的纪念.

现截取其中的 10 对数据如下(其中 x 为父母平均身高(单位:in,1 in=2.54 cm),y 为儿子身高):

序号	x/in	y/in	序号	x/in	y/in
1	60	63.6	6	67	67.1
2	62	65.2	7	68	67.4
3	64	66	8	70	68.3
4	65	65.5	9	72	70.1
5	66	66.9	10	74	70

(1) 构造成年儿子身高 y 关于父母平均身高 x 的散点图,该散点图是否提示两者之间存在线性关系?

(2) 给出成年儿子身高 y 关于父母平均身高 x 的最小二乘回归直线.

第二节　一元线性回归的检验和置信推断

一、确定系数 R^2

在实际问题中,响应变量总是有变异的,回归分析的一个重要目的在于确定选用的最小二乘回归直线能够解释这种变异的程度.

描述响应变量变异程度的一个指标为总平方和

$$SST = \sum_{i=1}^{n} (y_i - \bar{y})^2 = \sum_{i=1}^{n} y_i^2 - n(\bar{y})^2, \tag{6}$$

注意到与 SSE 的表达式(5)相比较,SSE 是关于最小二乘回归直线的偏差平方和,而 SST 是关于水平直线 $y=\bar{y}$ 的偏差平方和.如记

$$SSR \triangleq SST-SSE,$$

容易证明

$$SSR = \sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2, \tag{7}$$

我们称 SSR 为回归平方和.注意到,残差平方和 SSE 是总体变异中扣除为回归直线所解释的剩余部分的平方和.因此 SSR 正好是响应变量的变异为回归直线所解释的那部分

平方和.于是我们得到一个平方和分解式

$$SST=SSR+SSE, \tag{8}$$

而且可以使用这些平方和定义回归分析中的一个重要指标,即确定系数:

$$R^2=\frac{SSR}{SST}\left(=1-\frac{SSE}{SST}\right). \tag{9}$$

按各平方和的含义可知,确定系数是响应变量的变异为回归直线所解释的那部分变异在总变异中所占的比例.注意到由(8)式可知 $0\leqslant SSR\leqslant SST$,因此

$$0\leqslant R^2\leqslant 1.$$

如果 $R^2=1$,表明总变异的 100%可以为回归直线所解释,此时两变量 x,y 完全线性相关,数据集的每一点都落在最小二乘直线上(事实上,由 $R^2=1$ 即知 $SSE=0$,由 SSE 定义即可推出 $y_i=\hat{y}_i, i=1,2,\cdots,n$).因此从这个角度看,$R^2$ 也是回归直线拟合数据的拟合程度的度量,较好的拟合,R^2 接近 1;较弱的线性关系或没有线性关系,则 R^2 接近 0.

例 5(例 2 续)　计算儿童睡眠数据的确定系数.首先注意到有一个 SSE 的等价的计算式(见习题 12.2 第 5 题):

$$SSE=\sum_{i=1}^{n}y_i^2-\hat{a}\sum_{i=1}^{n}y_i-\hat{b}\sum_{i=1}^{n}x_iy_i,$$

代入例 3 的结果

$$\hat{a}=645.420\ 5,\quad \hat{b}=-13.947\ 4$$

及 $n=13$, $\bar{y}=519.303\ 8$, $\sum_{i=1}^{n}x_iy_i=59\ 744.27$, $\sum_{i=1}^{n}y_i^2=3\ 525\ 918$,立即可得

$$SSE=1\ 993.707.$$

又

$$SST=\sum_{i=1}^{n}(y_i-\bar{y})^2=\sum_{i=1}^{n}y_i^2-n\bar{y}^2=20\ 124.323,$$

因此,

$$R^2=1-\frac{1\ 993.707}{20\ 124.323}=0.900\ 930.$$

也就是说,90.093 0%的儿童睡眠时间的观察变异可以为儿童睡眠时间与年龄之间的近似线性关系所解释,这是给人印象深刻的结果.这一点也可在数据的散点图上得到印证.

二、σ^2 的估计

一元线性回归模型(2)除了含有参数 a,b 外,尚隐含未知参数 σ^2,这是一个度量回归模型变异程度的参数,一个大的 σ^2 值表明数据集 (x_i,y_i), $i=1,2,\cdots,n$ 将围绕真回归直线有较大的波动;而对于小的 σ^2,则数据非常接近回归直线.

为构造 σ^2 的估计,我们回顾残差平方和 SSE 的表达式(5),注意到,残差 $y_i-\hat{y}_i$ 是数据点到最小二乘回归直线的垂直偏差,残差平方和 SSE 是反映数据点围绕最小二乘

回归直线波动程度的一个综合指标，可以近似刻画数据围绕真回归直线的波动.因此我们定义 σ^2 的估计为

$$\widehat{\sigma^2} = S^2 = \frac{SSE}{n-2} = \frac{1}{n-2}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2, \tag{10}$$

此处分母 $n-2$ 是与估计相伴的自由度(因为为得到残差，必须估计两个参数 a 及 b，所以损失 2 个自由度).S^2 的算术平方根 S 定义为标准差 σ 的估计.可以证明 S^2 是 σ^2 的无偏估计(但 S 不是 σ 的无偏估计).

例 6 在高三阶段，每个学生都会参加若干次的模拟考试，按以往经验，模拟考试成绩必然与高考成绩在数值上存在密不可分的关系.为探究并验证高考成绩与模拟考试成绩之间的线性回归关系，采集了某高中 44 位学生的某一次模拟考试成绩 x(单位：分)和高考成绩 Y(单位：分)，汇总如下：

考生编号	模拟考试成绩	高考成绩	考生编号	模拟考试成绩	高考成绩	考生编号	模拟考试成绩	高考成绩
1	534	549	16	548	558	31	591	559
2	487	466	17	515	536	32	523	467
3	577	607	18	640	637	33	650	583
4	658	656	19	639	611	34	577	545
5	536	516	20	589	607	35	594	531
6	554	573	21	611	585	36	519	505
7	594	549	22	625	632	37	611	569
8	508	526	23	546	528	38	455	635
9	579	560	24	561	553	39	568	579
10	623	636	25	625	574	40	590	599
11	581	583	26	625	593	41	615	593
12	663	605	27	577	523	42	561	583
13	534	511	28	565	603	43	587	580
14	613	599	29	656	644	44	596	561
15	581	548	30	602	563			

其散点图如图 12.5 所示.

散点图显示 x 与 Y 有简单的线性关系，经计算，有

$$\sum_{i=1}^{44} x_i = 25\,583, \quad \sum_{i=1}^{44} x_i^2 = 14\,969\,851,$$

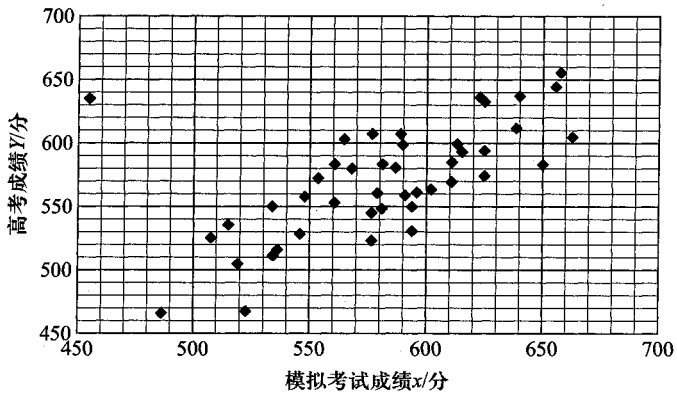


图 12.5

$$\sum_{i=1}^{44} y_i = 25\ 120, \quad \sum_{i=1}^{44} x_i y_i = 14\ 660\ 699, \quad \sum_{i=1}^{44} y_i^2 = 14\ 424\ 806,$$

因此

$$S_{xx} = \sum_{i=1}^{44} (x_i - \bar{x})^2 = 95\ 080.8, \quad S_{xy} = \sum_{i=1}^{44} (x_i - \bar{x})(y_i - \bar{y}) = 55\ 131.7,$$

$$\hat{b} = \frac{S_{xy}}{S_{xx}} = 0.579\ 8, \quad \hat{a} = \bar{y} - \hat{b}\bar{x} = 233.794\ 9, \quad SSE = \sum_{i=1}^{44} y_i^2 - \hat{a}\sum_{i=1}^{44} y_i - \hat{b}\sum_{i=1}^{44} x_i y_i = 51\ 604.83,$$

于是 σ^2 的估计

$$\widehat{\sigma^2} = \frac{SSE}{n-2} = 1\ 228.69,$$

而 σ 的估计 $\hat{\sigma} = 35.05$. 此时，$\widehat{\sigma^2}$ 值较大，因此数据相对于回归直线的波动也较大，这从散点图也可得到印证.

三、回归系数的显著性检验

回归系数 b 的含义是：当解释变量 x 有一个单位增量时，响应变量 Y 的改变量的真平均就是 b. 因此从平均意义上说，Y 与 x 的关联度是同回归系数 b 息息相关的. 一个极端的情况是 $b=0$，此时，Y 的变异只同随机误差 ε 有关而与 x 没有关系，这当然是必须首先排除的情况. 这可归结为假设 $H_0: b=0$ 的统计检验问题.

下面先陈述几个后文要用到的有关回归模型参数估计以及平方和统计量的结果.

定理 1 在一元线性回归模型(2)的假设条件下，有

(i) $\hat{b}$ 服从正态分布；

(ii) $E(\hat{b}) = b, D(\hat{b}) = \dfrac{\sigma^2}{S_{xx}}$；

(iii) $(\hat{a}, \hat{b})$ 与 $\widehat{\sigma^2}$ 相互独立；

(iv) $\frac{(n-2)\widehat{\sigma^2}}{\sigma^2}\sim\chi^2(n-2)$.

证明从略.

定理 2 在一元线性回归模型(2)的假设条件下,有

(i) $\frac{SSE}{\sigma^2}\sim\chi^2(n-2)$;

(ii) SSE 与 SSR 相互独立;

(iii) 当 $b=0$ 时,$\frac{SSR}{\sigma^2}\sim\chi^2(1)$.

证明见附录.

现在回到假设 H_0 的检验问题,考察作为回归系数 b 的估计 $\hat{b}=\frac{S_{xy}}{S_{xx}}$ 的统计性质,从定理 1 的(ii)知,估计量 $\hat{b}$ 有标准差 $\sigma_{\hat{b}}=\frac{\sigma}{\sqrt{S_{xx}}}$,如用 S 替代 σ,则得到 $\hat{b}$ 的标准差的估计 $\hat{\sigma}_{\hat{b}}=\frac{S}{\sqrt{S_{xx}}}$.文献上也称此为回归系数的标准误,也称为标准误差.定义 $T=\frac{\hat{b}}{S/\sqrt{S_{xx}}}$,我们有

定理 3 在一元线性回归模型(2)的假设条件下,若 H_0 成立,则有 $T\sim t(n-2)$.

证明见附录.

由定理 3 可以知道,T 是假设 H_0 的一个合适的检验统计量,且对给定的 $0<\alpha<1$,假设 H_0 的显著性水平 α 检验有拒绝域

$$R=\{|T|\geqslant t_{1-\frac{\alpha}{2}}(n-2)\},$$

或者基于观测数据得到统计量 T 的观测值 t,可以计算出 p 值

$$p\triangleq P(|T|\geqslant|t||H_0).$$

若 p 值很小,则应拒绝 H_0.

在实际应用中,不必直接计算 t 值及 p 值,只需使用常用统计软件,输入数据后,便可得到如下形式的回归分析表:

回归分析表

变量	参数估计	标准误差	T 值	p 值
常数项	*	*	*	*
x	*	*	*	*

此处“标准误差”这一列,是指参数估计量的标准差的估计值.

例 7 某快餐连锁店的人力资源部为研究职员出勤率与参加工作时间的关系,收集了下属 10 家门店的数据,其中 y 为每 100 名职员一周内的缺勤次数,x 为在门店工作的平均月数.

工作的平均月数 x	缺勤次数 y	工作的平均月数 x	缺勤次数 y
18.1	31.5	22.4	27.8
20	33.1	22.9	23.3
20.8	27.4	24	24.7
21.5	24.5	25.4	16.9
22	27	27.3	18.1

其散点图如图 12.6 所示.

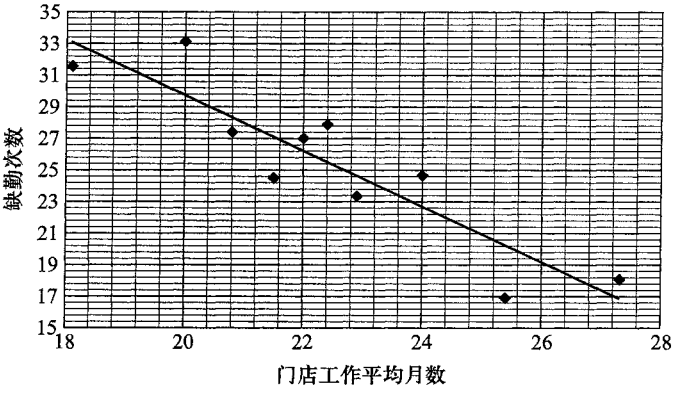


图 12.6

该图显示数据点明显落在一条下降直线周围,使用直线拟合是较为合理的.以下是由 Excel 的输出结果:

	Coefficients	标准误差	t Stat	P-value
Intercept	64.671 77	6.762 107	9.563 848	1.18E-05
X Variable 1	-1.748 74	0.299 457	-5.839 71	0.000 387

由此表可知,我们的线性回归模型的最小二乘回归直线为

$$\hat{y}=64.7-1.75x.$$

由于 p 值接近 0,因此回归系数是高度显著的,注意此处 b 值为负值,其含义是相应绝对值的减少,例如一家门店的员工如平均工作时间增加一个月,则每 100 名员工中在一周内平均缺勤次数减少 1.75 次.

我们从 Excel 的输出结果还可得到 σ 的估计 $s=2.388$,确定系数 $R^2=0.81$.

例 8 Houck 研究过铋 Ⅰ-Ⅱ的转移压力与温度的关系,他在每个给定温度下重复观测转移压力.以下是对同一组温度下的重复观测数据的平均值,得到 8 个平均转移压力(单位:bar,1 bar=0.1 MPa)y 与温度(单位:℃)x 的样本数据①.

① 本例数据来自 J.Res.Natl.Bur.Stand.,1970:74A,51-54.

温度 x/℃	压力 y/bar	温度 x/℃	压力 y/bar
21	25 352.7	25	25 143
22	25 276.3	34	24 751
22.5	25 235.3	42.7	24 429
23	25 157	50	24 103.7

其散点图如图 12.7 所示.

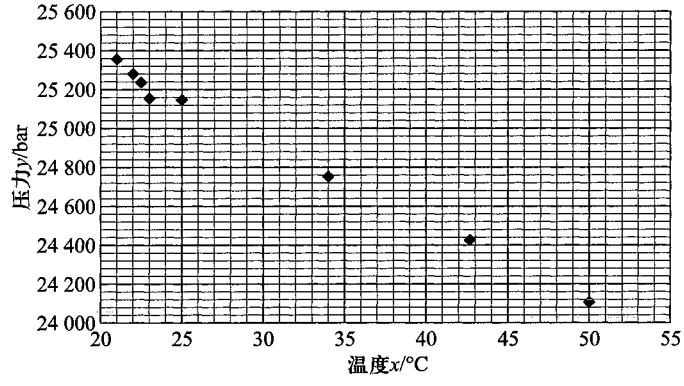


图 12.7

Excel 给出如下的回归分析表：

	Coefficients	标准误差	t Stat	P-value
Intercept	26 167.99	38.377 948	681.849 686 1	6.717E-16
X Variable 1	-41.198 7	1.2 087 513	-34.083 703 2	4.248E-08

可知最小二乘回归直线为$\hat{y}=26\ 167.99-41.198\ 7x$，且 p 值非常接近零，回归系数是高度显著的.事实上由 Excel 输出结果还可知 $R^2=0.994\ 9$，因此压力数据变异的 99.49% 可由压力与温度的线性关系所解释，回归直线的拟合度很好.

四、置信推断

在前段的回归系数显著性检验中，我们对于这样的问题："变量 x 与 y 之间是否存在线性关系"的回答找到支持的证据，但"这种'效应'有多大?"或者说"虽然 $b\neq 0$，但 b 的真值究竟是多少?"并未解决.注意由于种种原因参数估计不可能将一个未知参数估计得很准确，而量化参数估计准确程度的工具就是置信区间.因此，一旦通过了回归系数 b 的显著性检验，尚需做 b 的置信区间.我们可以从前段的论述得知(证明从略)

$$t=\frac{\hat{b}-b}{S/\sqrt{S_{xx}}}\sim t(n-2),$$

因此,可得 b 的置信水平为 $1-\alpha$ 的置信区间为

$$\left[\hat{b}-t_{1-\frac{\alpha}{2}}(n-2)\frac{S}{\sqrt{S_{xx}}},\hat{b}+t_{1-\frac{\alpha}{2}}(n-2)\frac{S}{\sqrt{S_{xx}}}\right].$$

例 9(例 7 续)　由例 7 的回归分析表可知,b 的估计 $\hat{b}=-1.75$,且回归系数的估计标准误为 0.299 457,对于给定 $1-\alpha=0.95$,有 $t_{1-\frac{\alpha}{2}}(n-2)=2.306$,因此由例 7 的数据,得到 b 的置信水平为 0.95 的置信区间的观测值为

$$(-1.75-2.306\times 0.299\ 457,-1.75+2.306\times 0.299\ 457),$$

即

$$(-2.440\ 5,-1.059\ 5),$$

注意到这个置信区间位于零点的左侧,且不含零点,因此给人以回归系数真值不为零的强烈印象,回归模型有较强的"效应".

例 10(例 8 续)　由例 8 的回归分析表可知,b 的估计 $\hat{b}=-41.198\ 7$,且回归系数的估计标准误为 1.208 751 3,对给定 $1-\alpha=0.95$,有 $t_{1-\frac{\alpha}{2}}(n-2)=t_{0.975}(6)=2.446\ 9$,因此由例 8 的数据,得到 b 的置信水平为 0.95 的置信区间的观测值为(-44.156 4,-38.241),这加深了回归系数的真值不为零的印象.

习题 12.2

1. 教育学家测试了 21 个儿童的年龄 x(单位:月)及某种智力指标 y,试建立智力随年龄变化的关系.从样本数据可算得:$\bar{x}=14.38$,$\bar{y}=93.67$,$\sum\limits_{i=1}^{21}x_i^2=5\ 606$,$\sum\limits_{i=1}^{21}y_i^2=188\ 155$,$\sum\limits_{i=1}^{21}x_iy_i=26\ 864$.

(1) 给出智力随年龄变化的最小二乘回归直线.

(2) 计算随机误差的标准误差估计 $\hat{\sigma}$;

(3) 计算 $D(\hat{b})$.

2. (习题 12.1 第 3 题续)

(1) 作回归系数 b 的显著性 T 检验,取显著性水平为 5%;

(2) 给出 b 的 95%置信区间;

*(3) 用 Excel 给出方差分析表.

3. (习题 12.1 第 4 题续)

(1) 求回归模型随机误差的标准误差估计 $\hat{\sigma}$;

(2) 作回归系数 b 的显著性 T 检验,取显著性水平为 5%;

*(3) 作出平方和分解并用 Excel 给出方差分析表.

4. (习题 12.1 第 5 题续)

*(1) 作回归系数 b 的显著性 F 检验,并列出方差分析表;

(2) 给出 b 的 90%置信区间.

*5. 证明:(1) $SSE=\sum\limits_{i=1}^{n}y_i^2-\hat{a}\sum\limits_{i=1}^{n}y_i-\hat{b}\sum\limits_{i=1}^{n}x_iy_i$;

(2) $SSE=\sum\limits_{i=1}^{n}(y_i-\bar{y})^2-\hat{b}\sum\limits_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})$.

第三节　预　　测

回归分析的主要应用有两个：一是描述和解释，前面的例子多是这方面的应用；二是预测，即基于对自变量的了解，或者说对给定自变量的值，去预测响应变量的相应值是多少，这也是回归分析的最重要的应用.本节将讨论如何进行回归分析预测.

一、对给定 x_0，响应变量值 y_0 的预测

先明确预测问题的提法，即在一元线性回归模型(2)的假定(i)—(iii)下，对于给定自变量 $x=x_0$(与 $x_1,x_2,\cdots,x_n$ 不同)，基于观测 $\{(x_i,y_i),i=1,2,\cdots,n\}$ 预测响应变量 $y_0(=y\big|_{x=x_0})$ 之值是多少？前已指出，预测与参数估计问题不同，预测对象是随机变量.这也是统计预测一个重要特点.要做预测必须回答两个问题：一是用什么作 y_0 的预测值？二是预测精度是多大？

今回答第一个问题，先设想 y_0 的期望即 $\xi_0=E(y_0)$ 是已知的(此处为记号简化起见，记 $E(y_0)=E(y\mid x_0)$).注意到 y_0 是随机的，其取值是不确定的，但 ξ_0 作为 y_0 中心位置的特征，对刻画 y_0 的取值情况是十分重要的，因而对 y_0 的不确定性缺乏进一步了解的情况下，将 ξ_0 作为 y_0 的预测值是合理的.这样做在理论上的好处在于以下事实：同其他所有可能的预测相比，ξ_0 是均方误差最小的预测，即对任何 y_0 的预测 $f(x_0)$，有

$$E[(y_0-\xi_0)^2]\leqslant E[(y_0-f(x_0))^2].$$

事实上，对任何预测 $f(x_0)$，有

$$E[(y_0-f(x_0))^2]=E[(y_0-\xi_0)^2]+(\xi_0-f(x_0))^2\geqslant E[(y_0-\xi_0)^2]$$

且等式当且仅当 $f(x_0)=\xi_0$ 成立.这就证明了前述断言.

但现在由于 a,b 未知，因而 y_0 的期望 $\xi_0=E(y_0)=a+bx_0$ 是未知的，不能直接将 ξ_0 用于预测.自然想到使用最小二乘原理得到的估计 $\hat{a},\hat{b}$ 替换 a,b，最终得到 y_0 的预测值为 $\hat{y}_0=\hat{a}+\hat{b}x_0$，其中 $\hat{a},\hat{b}$ 如(4)式所示.

对于第二个问题，描述预测精度的一个常用指标即均方误差.为计算预测 $\hat{y}_0$ 的均方误差，注意到预测偏差

$$y_0-\hat{y}_0=(\xi_0-\hat{y}_0)+\varepsilon_0,$$

即预测偏差分解成上式右边两个部分：$\xi_0-\hat{y}_0$ 及 ε_0.容易知道这两个部分是相互独立的，事实上，$\xi_0-\hat{y}_0$ 只与 $y_1,y_2,\cdots,y_n$ 有关，ε_0 只与 y_0 有关.而 $y_1,y_2,\cdots,y_n$ 与 y_0 是相互独立的，因而 $\xi_0-\hat{y}_0$ 与 ε_0 相互独立.现在我们可以计算预测 $\hat{y}_0$ 的均方误差，由独立性，

$$\begin{aligned}E[(y_0-\hat{y}_0)^2]&=E[(\xi_0-\hat{y}_0)^2]+E[(\varepsilon_0)^2]+2\mathrm{cov}(\xi_0-\hat{y}_0,\varepsilon_0)\\&=E[(\xi_0-\hat{y}_0)^2]+E[(\varepsilon_0)^2]\\&=D(\hat{y}_0)+D(\varepsilon_0),\end{aligned}$$

而

$$D(\hat{y}_0)=D(\hat{a}+\hat{b}x_0)=D(\bar{y}+(x_0-\bar{x})\hat{b})$$

$$=D(\bar{y})+(x_0-\bar{x})^2D(\hat{b})+2(x_0-\bar{x})\operatorname{cov}(\bar{y},\hat{b}),$$

注意到诸 y_i 相互独立，以及 $\sum_{i=1}^{n}(x_i-\bar{x})=0$，可知 $\operatorname{cov}(\bar{y},\hat{b})=0$. 再由定理 1 知 $D(\hat{b})=\dfrac{\sigma^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2}$，因而 $D(\hat{y}_0)=\sigma^2\left(\dfrac{1}{n}+\dfrac{(x_0-\bar{x})^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2}\right)$. 最后得到预测 $\hat{y}_0$ 的均方误差为

$$E[(y_0-\hat{y}_0)^2]=\sigma^2\left(1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2}\right). \tag{11}$$

从中也可看到，如果模型的误差方差 σ^2 很大，则即使获取更多的数据，也不能根本改善 $\hat{y}_0$ 的预测精度.

例 11 在例 7 中要预测 $x_0=21$ 个月的 100 个职工的周缺勤次数 y_0，我们得到 y_0 的预测值为 $\hat{y}_0=64.7-1.75x_0=27.95$. 即工作平均月数为 21 个月的 100 个职工，周缺勤数为 27.95 次.

二、y_0 的预测区间

从前段可知，预测 $\hat{y}_0$ 仅仅给出 y_0 的平均值的一个估计，我们通常还需要知道作为随机变量的 y_0，其可能取值的散布范围，也即寻找 y_0 的预测区间. 详而言之，对给定 $0<\alpha<1$，寻找一个区间，使得 y_0 落在该区间的概率至少为 $1-\alpha$，此时称此区间为 y_0 的预测区间，$1-\alpha$ 为置信水平.

由一元线性回归模型(2)的基本假定可以证明(证明从略)：

$$\frac{\hat{y}_0-y_0}{S\sqrt{1+\dfrac{1}{n}+\dfrac{(x_0-\bar{x})^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2}}}\sim t(n-2).$$

因此 y_0 的置信水平为 $1-\alpha$ 的预测区间为

$$\left[\hat{y}_0-t_{1-\frac{\alpha}{2}}(n-2)S\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2}},\ \hat{y}_0+t_{1-\frac{\alpha}{2}}(n-2)S\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2}}\right], \tag{12}$$

其中 $S=\sqrt{\dfrac{SSE}{n-2}}$(见(10)式)为总体标准差 σ 的估计.

如记 $k = t_{1-\frac{\alpha}{2}}(n-2)S\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2}}$，则预测区间(12)满足 $P(|y_0-\hat{y}_0|\leqslant k)=1-\alpha$.基此可以给出统计预测结果的一个更为直观的解释：若多次重复试验，每次计算出 $\hat{y}_0$ 及 k 值，并用 $\hat{y}_0$ 作 y_0 的预测值，则 $\hat{y}_0$ 并不会正好与 y_0 重合，而是落在 y_0 的左边或右边，且平均来说 100 次中有 $(1-\alpha)\times 100$ 次，以 $\hat{y}_0$ 为中心的区间 $(\hat{y}_0-k,\hat{y}_0+k)$ 是包含 y_0 的.顺便指出，回归模型预测的精度，也可以用预测区间(12)式的宽度即 $2t_{1-\frac{\alpha}{2}}(n-2)S\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2}}$ 来度量.这与前段提到的用预测 $\hat{y}_0$ 的均方误差(11)式表达精度在形式上是相似的.但区间宽度可计算，而均方误差则不然(由(11)式可知，其中含有未知参数 σ^2).此外从宽度公式中可见，当预测点 x_0 愈接近数据中心位置 $\bar{x}$ 时预测愈精确，而若预测点 x_0 偏离数据 $\{x_i\}$ 太远，则预测精度很差.

在实际操作中可使用统计软件，如对于例 7，要求 $x_0=22.4$ 或 30.4 时的 95%预测区间，有如下的输出结果：

Fit	标准误	95%C.I.
25.50	0.755	[19.72,31.28]
11.51	2.500	[3.54,19.48]

以上第一列的数字是预测值，第二列为标准误，而第三列则为 95%的预测区间.如 $x_0=22.4$ 的预测值为 25.50，而 $x_0=30.4$ 时的预测值为 11.51，95%的预测区间分别为 (19.72,31.28)，(3.54,19.48).注意到 $x_0=22.4$ 的预测区间宽度约为 11.56，而 $x_0=30.4$ 时的预测宽度约为 16，后者比前者要大，这正如前段所述，因为 $x_0=30.4$ 已经超出 x 的数据范围，对 x_0 的预测，实际上是一种外推，所以必然带来精度上的损失.

例 12(例 8 续) 对于例 8 的数据，下表列出由不同温度 x 的给定值，相应的压力 y 的置信水平为 95%的预测区间的计算结果：

温度 x	压力 y 观测值	压力 y 的预测值 $\hat{y}$	y 的 95%置信下限	y 的 95%置信上限
21	25 352.7	25 302.82	25 207.409 90	25 398.226 98
22	25 276.3	25 261.62	25 166.996 07	25 356.243 38
22.5	25 235.3	25 241.02	25 146.756 79	25 335.283 93
23	25 157	25 220.42	25 126.495 62	25 314.346 39
25	25 143	25 138.02	25 045.227 28	25 230.819 85
34	24 751	24 767.24	24 674.885 31	24 859.584 87
42.7	24 429	24 408.81	24 309.833 12	24 507.779 35
50	24 103.7	24 108.06	23 999.056 83	24 217.054 34

习题 12.3

1.（习题 12.1 第 5 题续）该公司预计下一周签发新保单的数目 $x_0=1\ 000$，给出需要的加班时间的置信水平为 95%的预测区间.

2.（习题 12.1 第 6 题续）

（1）计算确定系数 R^2 的值；

（2）某一正在考虑提供周日版的报纸，平日发行量为 500，给出该报纸周日发行量的置信水平为 95%的预测区间.



附 录

一、定理 2 及定理 3 的证明

定理 2 的证明：由定理 1 的(iv)知 $\dfrac{SSE}{\sigma^2}=\dfrac{(n-2)S^2}{\sigma^2}\sim\chi^2(n-2)$，即得证(i).又

$$SSR=\sum_{i=1}^{n}(\hat{y}_i-\bar{y})^2=\sum_{i=1}^{n}(\hat{a}+\hat{b}x_i-\bar{y})^2=\hat{b}^2\sum_{i=1}^{n}(X_i-\overline{X})^2=\hat{b}^2S_{xx},$$

由定理 1 的(iii)，$SSE=(n-2)\widehat{\sigma^2}$ 与 $\hat{b}$ 相互独立，从而有 SSE 与 SSR 相互独立，此即(ii)成立.

最后，当 $b=0$ 时，由定理 1 的(i)和(ii)可知 $\hat{b}\sim N\left(0,\dfrac{\sigma^2}{S_{xx}}\right)$，从而 $\sqrt{S_{xx}}\dfrac{\hat{b}}{\sigma}\sim N(0,1)$，因此 $\dfrac{SSR}{\sigma^2}=S_{xx}\dfrac{\hat{b}^2}{\sigma^2}\sim\chi^2(1)$，得证(iii)，故定理 2 成立.

定理 3 的证明：由上面的证明有 $X\equiv\sqrt{S_{xx}}\dfrac{\hat{b}}{\sigma}\sim N(0,1)$，再由定理 1 的(iv)$\chi^2\equiv\dfrac{(n-2)\widehat{\sigma^2}}{\sigma^2}=\dfrac{(n-2)S^2}{\sigma^2}\sim\chi^2(n-2)$，且由定理 1 的(iii)$(\hat{a},\hat{b})$ 与 $S^2=\widehat{\sigma^2}$ 相互独立，从而 χ^2 与 X 相互独立，由 t 分布的定义，即知

$$T=\frac{\hat{b}}{S/\sqrt{S_{xx}}}=\frac{X}{\sqrt{\chi^2/n-2}}\sim t(n-2).$$

二、回归模型的显著性检验及方差分析表

所谓回归模型是否显著的问题，即引入模型的诸多解释变量对响应变量的解释是否有效.但由于一元线性回归模型只有一个解释变量，因而回归模型的显著性等价于回

归系数的显著性(然而在多元线性回归的情况则不然,尽管本书不涉及多元情况).在此介绍回归模型显著性的 F 检验方法(它当然也可用于一元线性回归中的回归系数的显著性检验).我们要检验的假设仍然是 $H_0: b=0$,因为若 H_0 成立,则一元线性回归的解释变量与响应变量的变异没有任何关系,模型当然是无效的.

我们回顾平方和分解式(8),其中 SSR 是响应变量的变异为回归直线所解释的那部分平方和.若回归所引起的变异(用 SSR 度量)相对来说要比因随机误差引起的变异(用 SSE 度量)偏大,则应倾向于拒绝 H_0.然后经过适当修正,就得到如下的检验统计量:

$$F=\frac{SSR/1}{SSE/(n-2)},$$

由定理 2 可知,当 H_0 成立,$F\sim F(1,n-2)$,因而可以得到检验的拒绝域

$$R=\{F>F_{1-\alpha}(1,n-2)\},$$

其中 $0<\alpha<1$ 是检验水平.

在实际操作中,只要使用相应的统计软件并输入数据,就可输出用下述的称之为方差分析表形式表示的结果:

方差分析表(ANOVA)

方差来源	平方和	自由度	均方	F 值	p 值
回归	SSR	1	$MSR=SSR/1$	MSR/MSE	$P(F>F\text{值})=p\text{值}$
误差	SSE	$n-2$	$MSE=SSE/(n-2)$		
总和	SST	$n-1$			

其中 p 值即是

$$p=P(F>F_0\mid H_0),$$

而 F_0 是基于数据得到的 F 的观测值.

注意到,因 $SSR=\hat{b}^2S_{xx}$,可知 $F=(T)^2$.所以假设 H_0 的 t 检验与 F 检验是等价的.

下面我们以例 7 为例,统计软件输出如下结果:

方差分析表(ANOVA)

方差来源	平方和	自由度	均方	F 值	p 值
回归	194.45	1	194.45	34.10	0.000
误差	45.61	8	5.70		
总和	240.06	9			

注意此处 p 值一栏为 0.000,表明实际 p 值小于 0.000 5,因此回归是高度显著的.这同我们在例 7,使用 t 检验得到的结果是一致的.

小　结

在一元线性回归模型中，响应变量 Y 总是随机的，而解释变量 x 是可以给定的，Y 与 x 之间存在一种关联，其关系用

$$Y=a+bx+\varepsilon$$

来描述，其中 ε 是随机的，且假定对任何给定的 x，ε 服从均值 0，方差为 σ^2 的正态分布.称

$$y\equiv\mu(x)=a+bx$$

为真回归直线，b 为回归系数，ε 为随机误差，它表示 Y 的观测与回归直线对应值的偏差.因此诸样本观测点 (x_i,y_i)，$i=1,2,\cdots,n$ 并不是正好落在回归直线上.

最小二乘直线 $\hat{y}=\hat{a}+\hat{b}x$ 是使偏差平方和

$$Q(a,b)=\sum(y_i-(a+bx_i))^2$$

达到最小的那条直线，其中 $\hat{a},\hat{b}$ 由(4)式确定，分别为参数 a,b 的最小二乘估计.

确定系数 R^2 是响应变量的变异为回归直线所解释的那部分变异在总变异中所占的比例，是回归直线拟合数据的拟合度的度量.

在建立了回归模型以后，回归分析首先要回答的问题是回归系数是否显著，即进行假设 $H_0:b=0$ 的显著性检验.常用的检验是 t 检验(或等价的 F 检验)；当回归显著时，还需建立回归系数的置信区间.

基于观测样本，对给定自变量的值 x_0，去预测响应变量 y_0 的值，是回归分析的重要应用.通常使用最小二乘回归直线作预测，即确定 y_0 的预测值为 $\hat{y}_0=\hat{a}+\hat{b}x_0$.公式(12)给出了具有置信水平 $1-\alpha$ 的 y_0 的预测区间，其区间的长度可以作为度量预测精度的指标.

第十二章综合题

1. 根据某商店 2012 年至 2019 年营业额 X(单位：百万元)和利润值 Y(单位：百万元)的统计资料计算得：$\bar{x}=80.74$，$\bar{y}=48.6$，$\sum\limits_{i=1}^{8}x_i^2=60\,742$，$\sum\limits_{i=1}^{8}y_i^2=21\,967$，$\sum\limits_{i=1}^{8}x_iy_i=36\,506$.

(1) 试建立营业额 X 与利润值 Y 的最小二乘回归直线 $\hat{y}=\hat{a}+\hat{b}x$，并给出解释；

(2) 对建立的回归模型，给出确定系数 R^2，以及 $\widehat{\sigma^2}$；

(3) 作回归系数 b 的显著性 T 检验，取显著性水平为 5%；

(4) 给出回归系数 b 的置信区间，取置信水平为 95%；

(5) 又知该商店 2019 年的营业额达到 1.55 亿元，试对该商店 2020 年的利润值进行预测.

2. 在一个一元线性回归模型中，采集到了 20 条样本数据 $(x_1,y_1),(x_2,y_2),\cdots,(x_{20},y_{20})$，经过

Excel 计算得如下方差分析表和回归系数表.可是其中有 11 处的数字被涂掉了,请填写出表中带“☆”的选项.

方差分析表

方差来源	自由度	平方和	均方	F 值	p 值
回归	☆	☆	☆	☆	0.000 1
偏差	☆	48	☆		
总和	☆	200			

回归分析表

变量	DF	参数估计	标准误差	T 值	p 值
常数项	☆	1	0.1	☆	<0.001
x	☆	0.1	0.05	☆	0.04



第十二章自测题





第十二章习题参考答案

